TP558 - Tópicos avançados em Machine Learning:

Personalized Recommendation System Based on Collaborative Filtering for IoT Scenarios

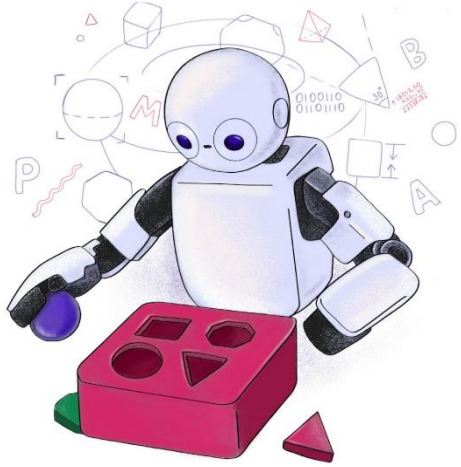

Inatel

Tiago de Morais Pereira
tiago.morais@mtel.inatel.br

Personalized Recommendation System Based on Collaborative Filtering for IoT Scenarios

- Autores: CUI, Zhihua; XU, Xianghua; XUE, Fei; CAI, Xingjuan; CAO, Yang; ZHANG, Wensheng; CHEN, Jinjun.
- Ano de publicação: 2020
- Local de publicação: IEEE Transactions on Services Computing
- Data da publicação: 1 jul. 2020
- DOI: https://doi.org/10.1109/tsc.2020.2964552

Contexto

- Crescimento de recursos de informações gerados por dispositivos IoT;
- Necessidade de mecanismos eficazes de filtragem e recomendação personalizada.

Problemas da área

- Algoritmos tradicionais de recomendação tendem a ser pouco eficazes em ambientes IoT por:
  - Serem lentos em ambientes de Big Data por compararem muitos dados;
  - Ignorarem a 'deriva de interesse', usuários mudam de preferência ao longo do tempo.

Motivação

- Sistema com recomendações rápidas e precisas;
- Adaptação em tempo real às mudanças de comportamento do usuário.

Objetivo

- Propor modelo TCCF (Time Correlation Coefficient + CSK-means)
  - Clusterização de usuários com interesses semelhantes;
  - Similaridade de interesses ao longo do tempo;
- Extensão do modelo TCCF -> PTCCF:
  - Personalização por padrões de usuários;
  - Implementa cálculo de diversidade para evitar recomendações muito parecidas;

Hipótese

- Combinar clusterização com coeficiente de correlação com sensibilidade temporal otimiza as recomendações em Big Data;

Contribuições

- Novo algoritmo de Filtragem Colaborativa (CF) baseado em Coeficiente de Correlação Temporal (TCC).
- Otimização do K-means usando Busca Cuckoo (CSK-means) para evitar ótimos locais na inicialização de clusters.
- Modelo PTCCF baseado em padrões de preferência e entropia temporal.

Fundamentação teórica - Conceitos

- Filtragem colaborativa:
  - Similaridade de interesse entre usuários
- K-means
  - Algoritmo de agrupamento;
  - Maximizar similaridade intra-cluster;
  - Minimizar similaridade inter-cluster
- Cuckoo search
  - Meta heurística baseada no comportamento de reprodução de pássaros (cuckoo);
  - Usado para encontrar os centróides iniciais dos clusters.

Fundamentação teórica - Trabalhos relacionados

- Improving collaborative recommendation via user-item subgroups
  - Bu et al. 2016;
  - Multiclass Co-Clustering (MCoC);
  - Subgrupos com usuários semelhantes;
  - Melhora nas recomendações.
- Use of social network information to enhance collaborative filtering performance
  - Liu et al. 2010;
  - Usa conexões em redes sociais para recomendar conteúdo semelhante para pessoas conectadas;
  - Depende das informações de redes sociais dos usuários.

Metodologia – Base de dados

- MovieLens-100M
  - Recomendações usuário x filme
  - 10 milhões de classificações
- Douban
  - Notas de 1 a 5;
  - Livros, músicas e filmes;
- Taxa de treinamento x teste: 80:20

Metodologia - Modelos

- K-means + Cuckoo search
  - Inicializa os centróides dos clusters a partir do Cuckoo search;
  - Agrupa os dados de forma iterativa visando maximizar a similaridade intra-cluster e minimizar a similaridade inter-cluster.

Metodologia - Modelos

- TCC (Time Correlation Coefficient)
  - Modifica o cálculo de similaridade de Pearson para atenuar interações recentes;

$$tcc_i = 1 - \frac{1}{\sqrt{2\pi}\sigma}\left(1 - \exp\left(-\frac{\Delta t^2}{2\sigma^2}\right)\right)$$

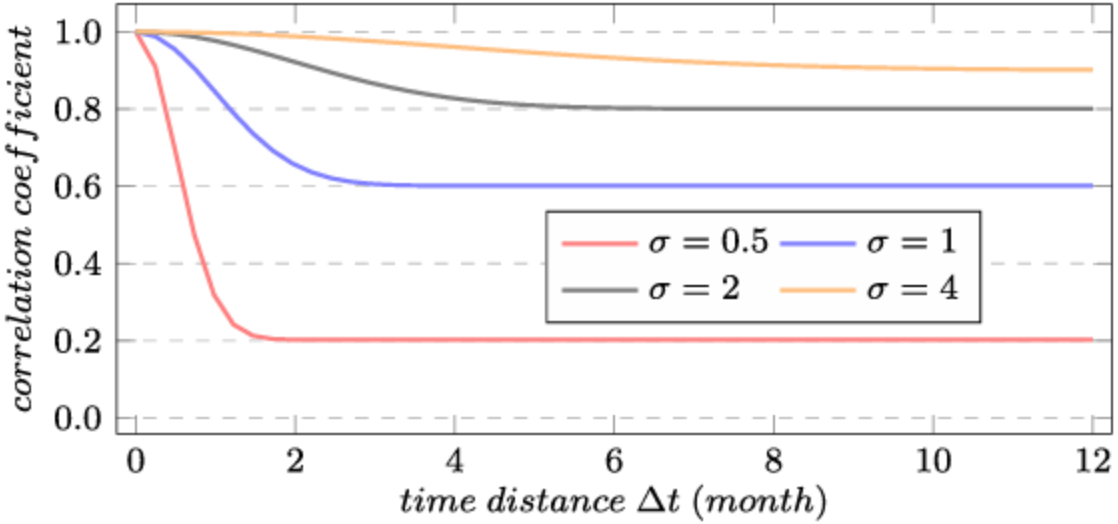

Metodologia - Modelos

- TCC (Time Correlation Coefficient)
  - r_u = Nota do usuário $$r'_u = r_u \times tcc.$$
  - u, v = usuários distintos

$$sim(u,v)_{new} = \frac{\sum_{i \in P_{uv}} (r'_{ui} - \overline{r'_u})(r'_{vi} - \overline{r'_v})}{\sqrt{\sum_{i \in P_{uv}} (r'_{ui} - \overline{r'_u})^2} \sqrt{\sum_{i \in P_{uv}} (r'_{vi} - \overline{r'_v})^2}}$$

$$P_{ui} = \overline{r_u} + \frac{\sum_{v \in NBS_u} sim(u,v) \times (r_{vi} - \overline{r_v})}{\sum_{v \in NBS_u} sim(u,v)}$$

Metodologia - Modelos

- Equação de diversidade:

$$dv(i) = \frac{fr(i)}{\alpha \cdot k(i) + 1}$$

$$k(i) = \sum_{j \in Set_B} sim(i, j)$$

$$sim(i, j) = \frac{\sum_{u \in U} (r_{u,i} - \overline{r_i})(r_{u,j} - \overline{r_j})}{\sqrt{\sum_{u \in U} (r_{u,i} - \overline{r_i})^2} \sqrt{\sum_{u \in U} (r_{u,j} - \overline{r_j})^2}}$$

Metodologia - Fluxo

- Cria clusters usando CSK-means;
- Identifica o cluster do usuário;
- Busca pelas recomendações pela equação do TCC;
- TCCF
  - Se o usuário for novo, recomenda os itens mais populares;
- PTCCF
  - Separa os usuários em padrões;
  - Aplica equação da diversidade;
  - Se o usuário for novo, recomenda os itens diversos.

Resultados - Seleção de parâmetros

- Métricas
  - MAE: Erro médio absoluto
  - MAP: Precisão média
- K - número de clusters (fixando sigma em 1)
  - Avaliação no dataset MovieLens. O resultado do dataset Douban é semelhante

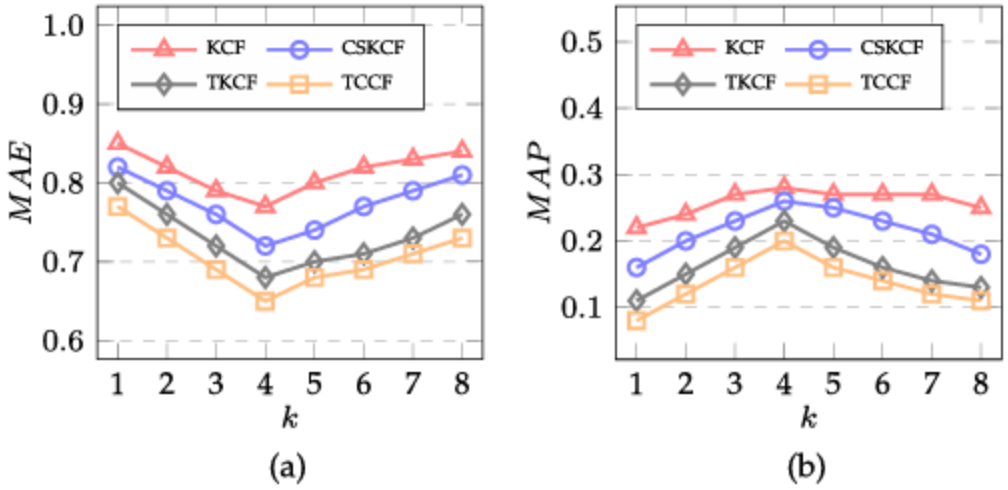

Resultados - Seleção de parâmetros

- Métricas
  - MAE: Erro médio absoluto
  - MAP: Precisão média
- K - número de clusters (fixando sigma em 1)
  - Avaliação no dataset MovieLens. O resultado do dataset Douban é semelhante

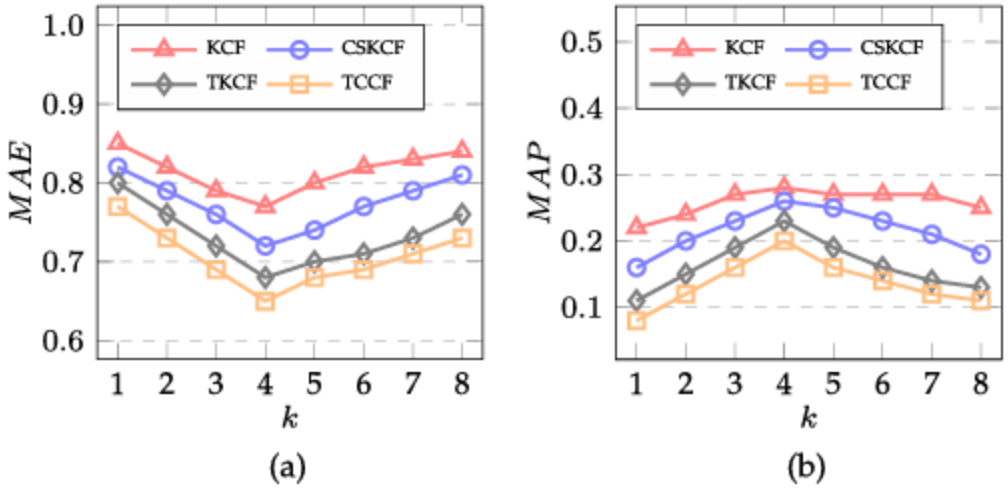

K = 4

Resultados - Seleção de parâmetros

- sigma – coeficiente de correlação temporal (fixando k em 4)
  - Avaliação no dataset MovieLens. O resultado do dataset Douban é semelhante

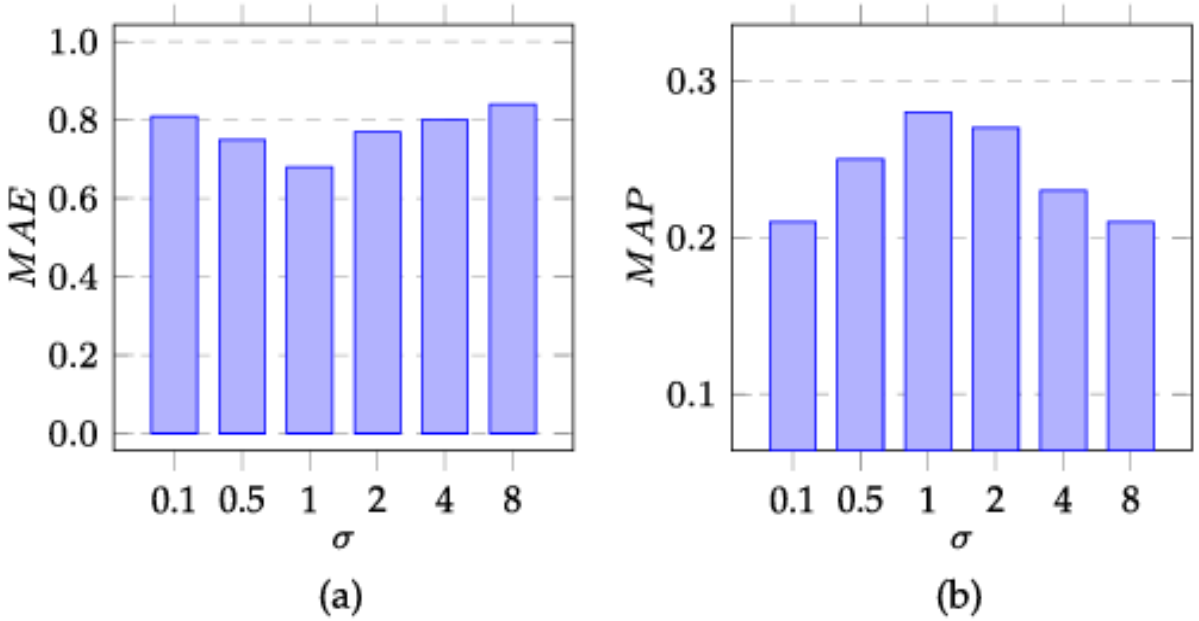

Resultados - Seleção de parâmetros

- sigma – coeficiente de correlação temporal (fixando k em 4)
  - Avaliação no dataset MovieLens. O resultado do dataset Douban é semelhante

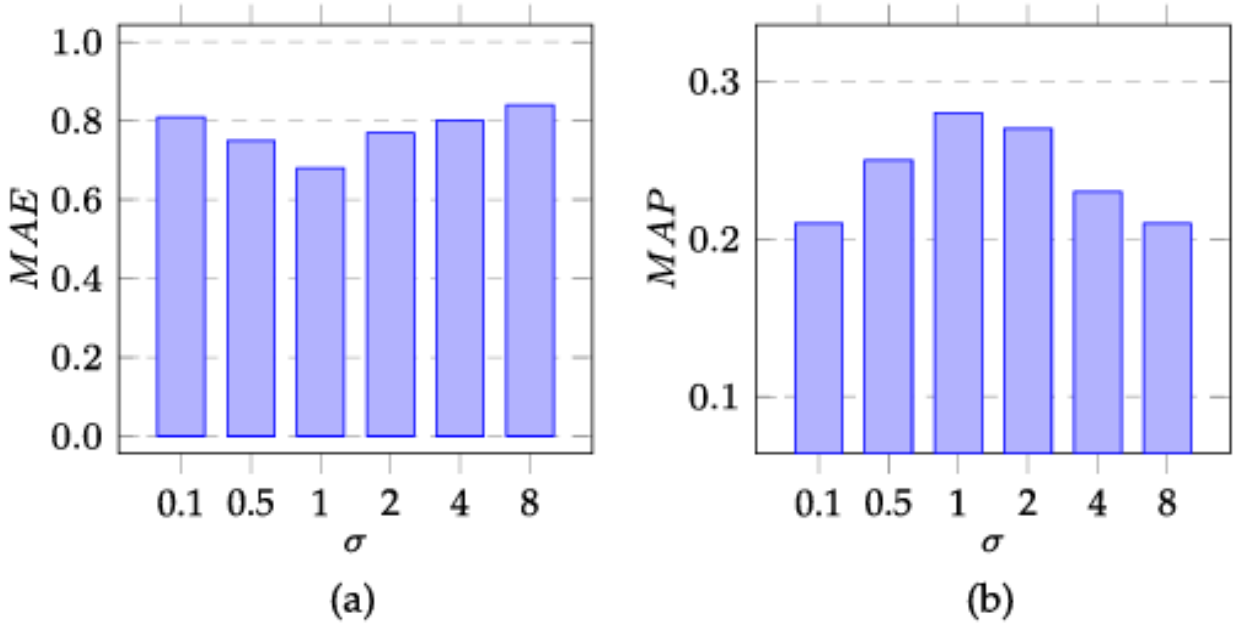

Sigma = 1

Resultados - Comparações

- N(i) = itens recomendados
- M(i) = itens consumidos

$$R = \frac{|N(i) \cap M(i)|}{|M(i)|}$$

$$P = \frac{|N(i) \cap M(i)|}{|N(i)|}$$

$$F - measure = \frac{2 * P * R}{P + R},$$

Resultados - Comparações

TABLE 3
Performance Comparisons With PMF, BPMF, SVD++ and MCoC on MovieLens and Douban

Dataset	Recommended method	N=10			N=20			N=50		
		P	F-measure	F	P	F-measure	F	P	F-measure	P
MovieLens	PMF	0.074	0.042	0.095	0.074	0.061	0.033	0.052	0.027	0.0679
	BPMF	0.102	0.053	0.11	0.102	0.093	0.049	0.086	0.041	0.087
	SVD++	0.269	0.159	0.259	0.269	0.258	0.148	0.249	0.137	0.241
	MCoC	0.275	0.145	0.256	0.275	0.267	0.137	0.261	0.126	0.245
	PTCCF	0.293	0.167	0.281	0.293	0.284	0.151	0.272	0.136	0.263
Douban	PMF	0.08	0.044	0.098	0.073	0.041	0.089	0.067	0.037	0.072
	BPMF	0.108	0.055	0.105	0.101	0.052	0.104	0.093	0.045	0.098
	SVD++	0.275	0.161	0.271	0.268	0.158	0.253	0.251	0.154	0.247
	MCoC	0.281	0.147	0.263	0.274	0.144	0.25	0.268	0.142	0.264
	PTCCF	0.297	0.169	0.297	0.292	0.166	0.281	0.286	0.162	0.291

Resultados - Diversidade

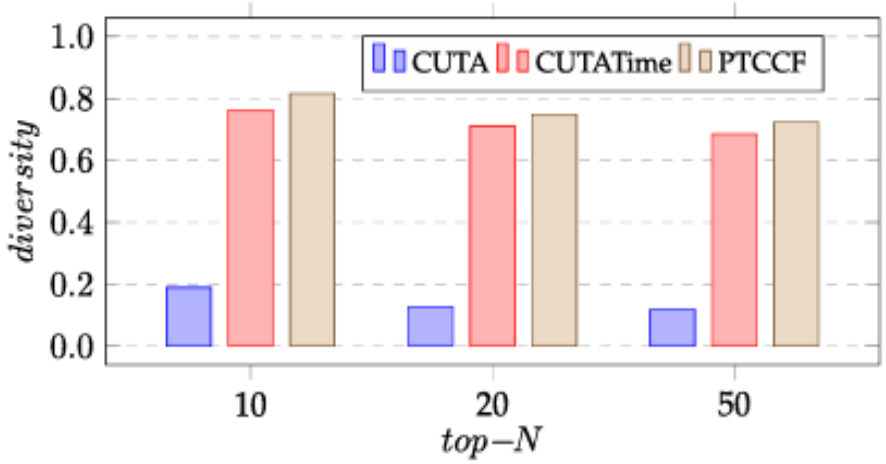

(a) *MovieLens*

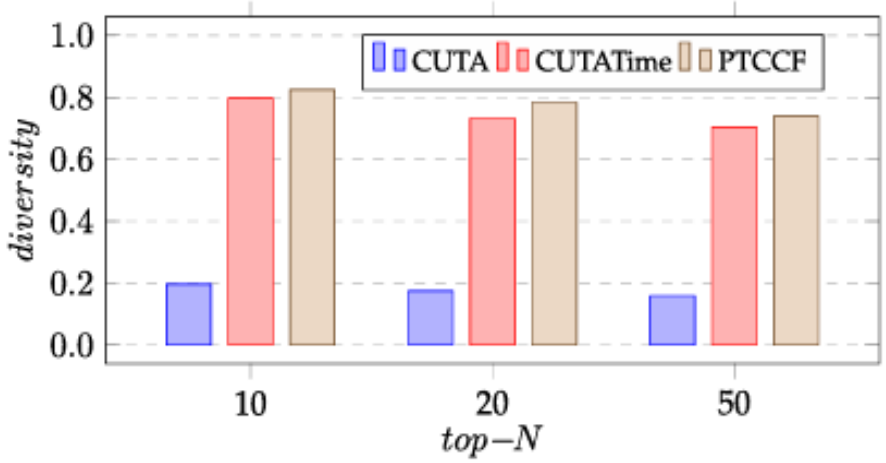

(b) *Douban*

Resultados - Paralelização com spark

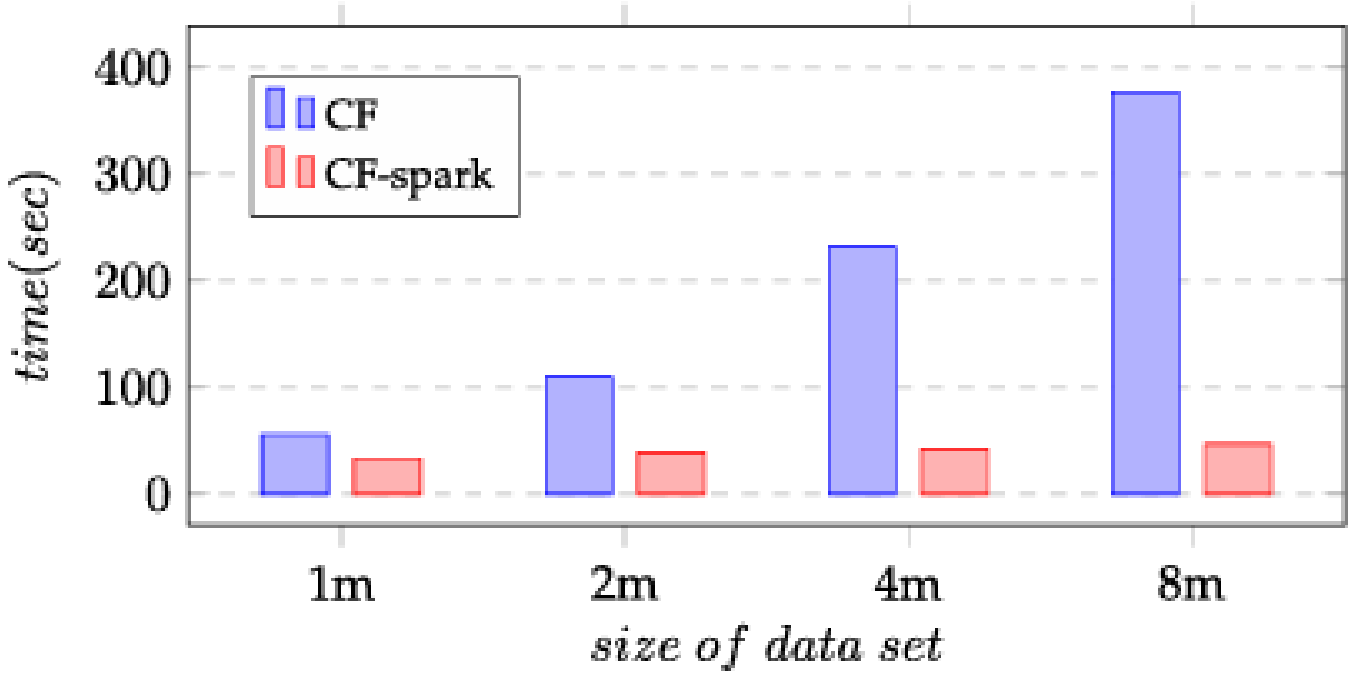

Resultados

- PTCCF demonstrou melhores resultados comparados aos demais modelos quando analisada a métrica F-measure;
- PTCCF apresentou melhor capacidade de recomendar dados com diversidade comparado aos demais modelos;
- Paralelizar as operações diminuiu drasticamente o tempo de processamento;
- À medida que aumenta o número de recomendações (N) a qualidade do modelo degrada.

Pontos fortes

- Integração de fatores temporais para resolver a "deriva de interesse";
- Redução do espaço comparativo, e consequentemente aparente redução do tempo de execução, com o emprego de agrupamento.

Limitações

- Desconexão com IoT
  - Embora o título cite IoT, os experimentos usam datasets de entretenimento (filmes/livros). Não há dados de sensores ou dispositivos típicos de IoT.
- Falta de comparação para validar a redução de tempo
  - Os autores citam o consumo de tempo como um desafio para recomendação em datasets grandes e propõem a clusterização para diminuir a amostra de comparação. Entretanto não mostram nenhuma comparação do tempo de execução com e sem clusterização.
- Equações e termos sem definição prévia
  - Algumas equações e tomadas de decisão não estão explícitas no texto, como a origem da função 'fr(i)' na equação de diversidade e a opção por representar 'ln' como 'log', tradicionalmente usado para base 10.

Possíveis melhorias

- Aplicar o estudo em datasets de IoT;
- Comparar o tempo de execução com e sem a aplicação de clusters.

Conclusão - Síntese

- O modelo TCCF/PTCCF propõe uma otimização para o gargalo de velocidade via clusterização inteligente e aumenta a precisão via análise temporal.

Conclusão - Impactos

- Demonstra como a "deriva de interesse" é importante para a modelagem de recomendação.

Direções futuras

- Explorar modelos para o comportamento do usuário (modelo Gaussiano);
- Aplicar o PTCCF em datasets voltados a IoT.

Perguntas?

Links de referência

- Colab: https://colab.research.google.com/drive/1e7b4Sw5_t9wUv6XtjCutAHDlipm9tv-D;
- GitHub: https://github.com/TiagoMPereira/TP558;
- Quis: TP558 - Ciclo I - Tiago Pereira – Preencher o formulário.

Referências

- CUI, Zhihua; XU, Xianghua; XUE, Fei; CAI, Xingjuan; CAO, Yang; ZHANG, Wensheng; CHEN, Jinjun. Personalized Recommendation System Based on Collaborative Filtering for IoT Scenarios. IEEE Transactions on Services Computing, [S.l.], v. 13, n. 4, p. 685–695, 1 jul. 2020. DOI: https://doi.org/10.1109/tsc.2020.2964552. Disponível em: http://dx.doi.org/10.1109/TSC.2020.2964552.
- BU, Jiajun; SHEN, Xin; XU, Bin; CHEN, Chun; HE, Xiaofei; CAI, Deng. Improving Collaborative Recommendation via User-Item Subgroups. IEEE Transactions on Knowledge and Data Engineering, [S.l.], v. 28, n. 9, p. 2363–2375, 1 set. 2016. DOI: https://doi.org/10.1109/tkde.2016.2566622. Disponível em: http://dx.doi.org/10.1109/TKDE.2016.2566622.

Referências

- LIU, Fengkun; LEE, Hong Joo. Use of social network information to enhance collaborative filtering performance. Expert Systems with Applications, [S.l.], v. 37, n. 7, p. 4772–4778, jul. 2010. DOI: https://doi.org/10.1016/j.eswa.2009.12.061. Disponível em: http://dx.doi.org/10.1016/j.eswa.2009.12.061.

Obrigado!