TP558 - Tópicos avançados em Machine Learning:

An evaluation review of user similarity metrics in sparse collaborative filtering datasets

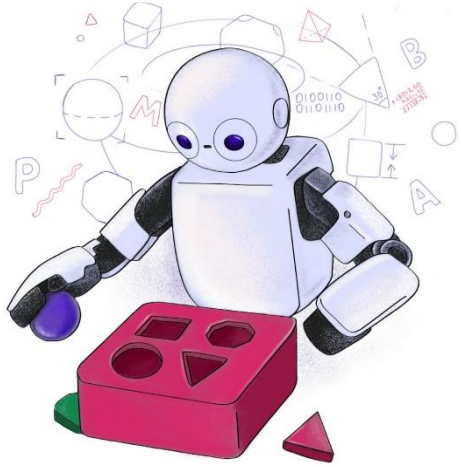

Inatel

Tiago de Morais Pereira
tiago.morais@mtel.inatel.br

An evaluation review of user similarity metrics in sparse collaborative filtering datasets

- Autores: Kiriakos Sgardelis, Dionisis Margaris, Dimitris Spiliotopoulos, Costas Vassilakis

- Ano de publicação: 2025
- Local de publicação: International Journal of Data Science and Analytics (2025)
- Data da publicação: 23 jun. 2025
- DOI: https://doi.org/10.1007/s41060-025-00846-4

Contexto

- "Caos" de informações na web. Sistemas de recomendação se tornam essenciais para encontrar informações relevantes;
- A Filtragem Colaborativa (CF) é uma das técnicas mais proeminentes nesses sistemas, baseada na premissa de que os usuários confiam em indivíduos com gostos semelhantes aos seus.

Problemas da área

- A identificação de usuários vizinhos confiáveis é extremamente desafiadora em bases de dados muito esparsas (sparsity ≥ 99%);
- A esparsidade resulta em uma menor precisão nas previsões de avaliação (ratings) dos sistemas;
- Diferentes trabalhos utilizam métricas distintas (como Cosseno ou Pearson), porém revisões e avaliações de literatura anteriores focaram primariamente em conjuntos de dados densos.

Motivação

- A seleção da métrica de similaridade mais eficiente é de vital importância e afeta consideravelmente o desempenho geral do sistema de recomendação;
- Compreender qual métrica gera resultados mais precisos auxilia a recomendação mais precisa.

Objetivo

- Avaliar a eficácia de 15 métricas de similaridade de usuários em conjuntos de dados de CF esparsos;
- Responder a três questões de pesquisa (RQs):
  - Quais métricas de similaridade geram os melhores resultados em dados esparsos?
  - Outros parâmetros do algoritmo afetam esse desempenho?
  - A comunidade deve continuar utilizando as métricas mais comuns (Pearson e Cosseno) ou mudar para outras?

Hipótese

- Métricas de similaridade amplamente usadas na literatura e prática, como o Coeficiente de Correlação de Pearson (PCC) e a Similaridade de Cosseno (COS), podem não ser as mais adequadas ou eficazes para atuar especificamente sobre dados altamente esparsos.

Contribuições

- Realização de uma bateria extensiva e multiparamétrica de testes focada unicamente na avaliação de bases nativamente esparsas;
- Comprovação de que a métrica de Spearman Rank Correlation (SP) supera amplamente métricas tradicionais em contextos de alta esparsidade.

Fundamentação teórica - Conceitos

- Filtragem Colaborativa (CF):
  - Algoritmo de recomendação em três passos (cálculo de similaridade, previsão de nota, e recomendação dos maiores valores).

	Item 1	Item 2	Item 3	Item 4	Item 5
User 1	0	3	0	3	4
User 2	4	0	0	2	0
User 3	0	0	3	0	0
User 4	3	0	4	0	3
User 5	4	3	0	4	4

Imagem disponível em: https://editor.analyticsvidhya.com/uploads/687331_4VYSoN1gIgBDnQUBimudKw.png. Acesso: 28/03/2026

Fundamentação teórica - Conceitos

- Dataset esparso:
  - Conjunto de dados onde grande maioria dos dados é 0 / nulo a depender da natureza dos dados;
  - Densidade:

$$\frac{\#ratings}{\#users * \#items}$$

  - Esparsidade: 1 - densidade

Fundamentação teórica - Conceitos

- Métricas de similaridade de usuário;
- Avaliadas 15 métricas:

  - Distância de Jaccard (JACC);
  - Distância de Manhattan (MANH);
  - Distância Euclidiana (EUCL);
  - **Distância de Chebyshev (CHEB);**
  - Correlação de Pearson (PCC);
  - **Correlação de Pearson com restrições (CPCC);**
  - Correlação de Pearson Sigmoid (SPCC);
  - Similaridade de Cosseno (COS);
  - Similaridade de Cosseno ajustada (ACOS);
  - **Ranqueamento de Spearman (SP);**
  - Kendall's Tau (TAU);
  - Diferença média dos quadrados (MSD);
  - Soma Ponderada Normalizada (NSM);
  - **Índice Ajustado de Rand (ARI);**
  - Informação Mútua Ajustada (AMI).

Fundamentação teórica - Correlação de Pearson (PCC)

56, 57]. It measures the linear correlation of U's and V's rating sets, while it is computed as shown in formula 8.

$$PCC(U,V) = \frac{\sum_{i \in I_{U,V}} (r_{U,i} - \bar{r_U}) * (r_{V,i} - \bar{r_V})}{\sqrt{\sum_{i \in I_{U,V}} (r_{U,i} - \bar{r_U})^2} * \sqrt{\sum_{i \in I_{U,V}} (r_{V,i} - \bar{r_V})^2}} \quad (8)$$

The range of this metric is [-1, 1], where higher values signify higher similarity between the two users [42].

Página 7 do artigo base [1]

Fundamentação teórica - Similaridade de Cosseno (COS)

$$COS(U, V) = \frac{\sum_{i \in I_{U,V}} r_{U,i} * r_{V,i}}{\sqrt{\sum_{i \in I_{U,V}} r_{U,i}^2} * \sqrt{\sum_{i \in I_{U,V}} r_{V,i}^2}} \quad (11)$$

In general, the range of the COS is [-1, 1], and higher values signify higher similarity between the two users. For datasets having non-negative rating values, such as the ones used in our experimental evaluation, the range of this metric is [0, 1].

Página 8 do artigo base [1]

Fundamentação teórica - Índice de Chebyshev (CHEB)

$$d_CHEB(U, V) = \max_{i \in I_{U,V}} |r_{U,i} - r_{V,i}| \tag{6}$$

Formula 6 is then normalised using equation 7 to compute the CHEB CF similarity metric [48].

$$CHEB(U, V) = \frac{1}{1 + d_CHEB(U, V)} \tag{7}$$

Página 7 do artigo base [1]

Fundamentação teórica - Correlação de Pearson com restrições (CPCC)

The constrained PCC (CPCC) is a variant of the PCC. It is differentiated from the original PCC, through the replacement of the average value of all ratings entered by each user $\bar{r_U}$ and $\bar{r_V}$, in the numerator, by the median value in the rating scale (r_{med}), as shown in formula 9.

$$CPCC(U,V) = \frac{\sum_{i \in I_{U,V}} (r_{U,i} - r_{med}) * (r_{V,i} - r_{med})}{\sqrt{\sum_{i \in I_{U,V}} (r_{U,i} - r_{med})^2} * \sqrt{\sum_{i \in I_{U,V}} (r_{V,i} - r_{med})^2}} \quad (9)$$

The range of this metric is [-1, 1], where higher values signify higher similarity between the two users [50].

Página 8 do artigo base [1]

Fundamentação teórica - Ranqueamento de Spearman (SP)

rank. When all rating values entered by the same user are distinct (i.e. a total ordering exists for rating values entered by the same user), SP is calculated using formula 13. In the general case where duplicate values for ratings may exist, SP is calculated using formula (14). In formula 14, R_U and R_V designate the ratings of the commonly rated items by these users, after these ratings have been converted to ranks, and $\sigma(R_x)$ designates the standard deviation of rank variable R_x.

$$SP(U,V) = 1 - \frac{6 * \sum_{i \in I_{U,V}} (Rank(r_{U,i}) - Rank(r_{V,i}))}{|I_{U,V}| * (|I_{U,V}| - 1)} \tag{13}$$

$$SP(U,V) = \frac{covariance(R_U, R_V)}{\sigma(R_U) * \sigma(R_V)} \tag{14}$$

The range of this metric is [-1, 1], where higher values signify higher similarity between the two users [51].

Página 9 do artigo base [1]

Fundamentação teórica - Índice Ajustado de Rand (ARI) [Índice Rand]

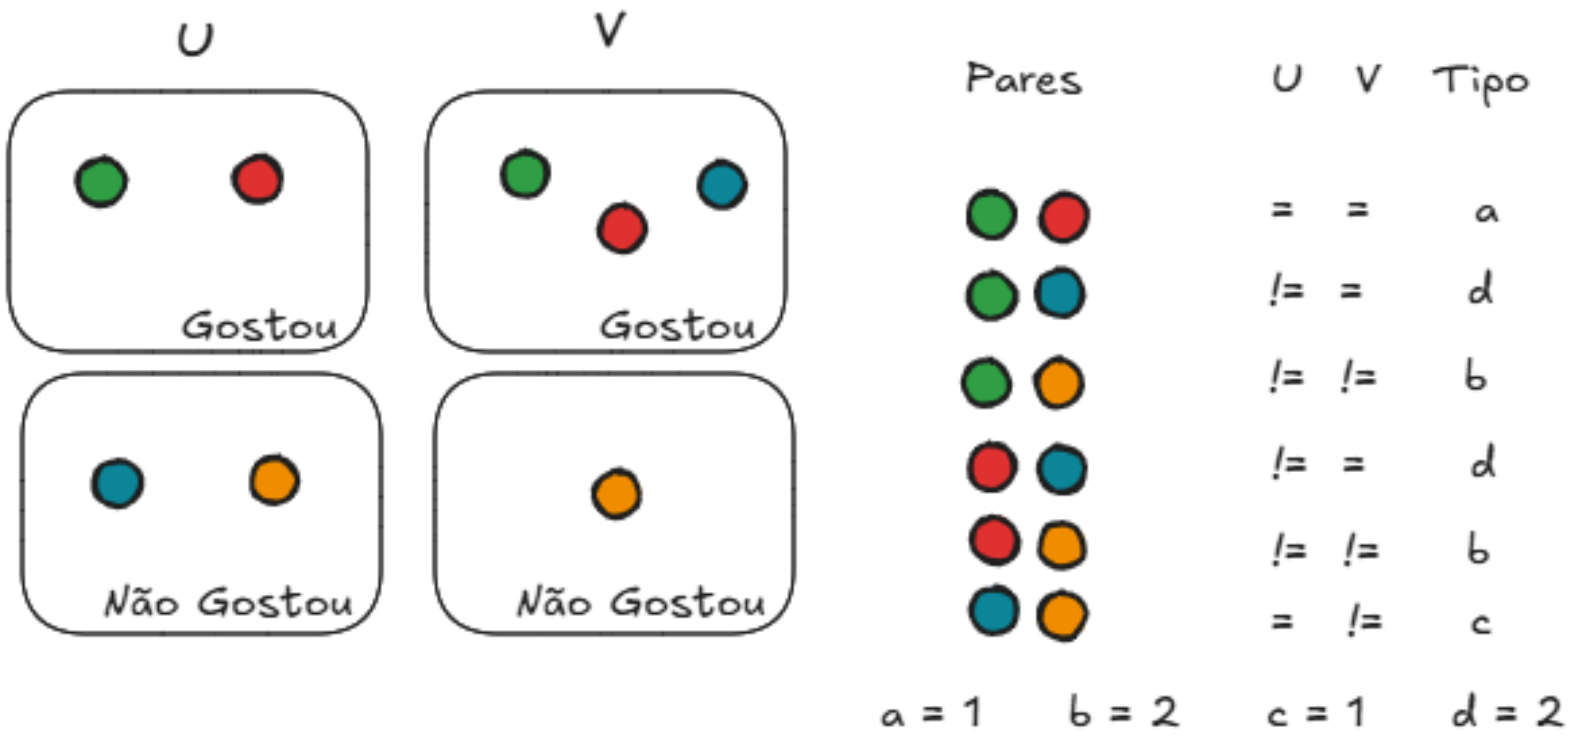

Ilustração criada pelo autor

$$R = \frac{a+b}{a+b+c+d} = \frac{a+b}{\binom{n}{2}}$$

Fundamentação teórica - Índice Ajustado de Rand (ARI)

$$ARI(U,V) = \frac{RI(U,V) - E\{RI(U,V)\}}{max(RI(U), RI(V)) - E\{RI(U,V)\}} \quad (20)$$

where RI is the Rand Index metric and E{RI(U,V)} is the expected Rand index between the two clusters U and V. The range of this metric is [-1, 1], where higher values signify higher similarity between the two users.

Página 10 do artigo base [1]

Fundamentação teórica - Trabalhos relacionados

- *Similarity measures for collaborative filtering-based recommender systems: Review and experimental comparison* (2022) [2] (referenciado como [31] na tabela 2);
- *Survey of similarity functions on neighborhood-based collaborative filtering* (2021) [3](referenciado como [32] na tabela 2);
- *Enhancing recommendation systems performance using highly-effective similarity meaures* (2021) [4](referenciado como [33] na tabela 2);
- *A survey of similarity measures for collaborative filtering-based recommender system* (2020) [5](referenciado como [38] na tabela 2);
- *A comparative analysis of similarity metrics on sparse data for clustering in recommender systems* (2019) [6](referenciado como [39] na tabela 2).

Fundamentação teórica - Trabalhos relacionados

Página 6 do artigo base [1]

Table 2 Similarity measures considered in recent surveys [31–33, 38, 39]

Similarity metric	Fkih [31]	Khojamli [32]	Amer [33]	Jain [38]	Bojorque [39]
Jaccard	✓	✓	✓	✓	✓
Manhattan	✓	✓		✓	
Euclidean	✓	✓		✓	✓
Chebyshev	✓				
Pearson	✓	✓	✓	✓	✓
Constrained Pearson			✓	✓	
Sigmoid Pearson			✓	✓	
Cosine	✓	✓	✓	✓	
Adjusted cosine	✓		✓		
Spearman rank	✓	✓	✓		
Kendall's Tau	✓				
Mean square difference		✓	✓		✓
Normalised sum of multiplications			✓		
Adjusted Rand index	✓				
Adjusted mutual information	✓				

Metodologia – Base de dados

- Foram utilizadas 10 bases de dados esparsas (>99%)

Página 5 do artigo base [1]

Table 5 Datasets used in the experiments

Dataset Name	Sparsity	#users	#items	#ratings	Ratings range
R4-Yahoo! Movies[1]	99.76%	8K	12K	221K	1–5
Book-crossing (books)[2]	99.997%	105K	341K	1 M	0–10
Amazon VideoGames[3]	99.951%	17K	55K	473K	1–5
Amazon CellPhones and Accessories[3]	99.985%	48K	157K	1.1M	1–5
Amazon Movies and TV[3]	99.982%	60K	298K	3.3M	1–5
Amazon Kindle Store[3]	99.984%	99K	140K	2.2M	1–5
Amazon Digital Music[3]	99.926%	12K	17K	145K	1–5
Amazon Musical Instruments[3]	99.925%	11K	28K	219K	1–5
Epinions (general consumer reviews)[4]	99.986%	22K	296K	922K	1-5
CiaoDVD (DVDs)[5]	99.91%	2K	17K	36K	1-5

Fundamentação teórica - Seleção de vizinhos próximos

- TOP-K:
  - Dadas as distâncias entre o usuário alvo e os seus vizinhos, seleciona os K vizinhos mais próximos para realizar a colaboração;
  - Valores usados: 250 e 500

- Valor limite (threshold):
  - Dadas as similaridades entre o usuário alvo e os seus vizinhos, seleciona todos os vizinhos cuja similaridade seja maior que um valor mínimo para realizar a colaboração;
  - Valores usados:0, 0.25, 0.5

Fundamentação teórica - Predição

- Soma ponderada:
  - Considera a nota que os vizinhos V do usuário U deram para o item I, ponderado pela similaridade de V com U.

$$p_{U,i} = \frac{\sum_{V \in NN_U} sim(U, V) * r_{V,i}}{\sum_{V \in NN_U} sim(U, V)} \tag{22}$$

Página 12 do artigo base [1]

Fundamentação teórica - Predição

- Previsão centrada na média:
  - Considera a nota que os vizinhos V do usuário U deram para o item I, porém subtraída da média das notas de V para abranger diferentes comportamentos de usuários. Centraliza as notas na média do usuário U.

$$p_{U,i} = \bar{r_U} + \frac{\sum_{V \in NN_U} sim(U, V) * (r_{V,i} - \bar{r_V})}{\sum_{V \in NN_U} sim(U, V)} \qquad (23)$$

Página 12 do artigo base [1]

Metodologia - Fluxo

- Cálculo da vizinhança utilizando uma das métricas de similaridade;
- Seleção dos vizinhos próximos com duas abordagens:
  - **Top-k:** K=250 e K=500
  - **Threshold:** THR=0.0, THR = 0.25 e THR=0.5
- Predição através de duas funções
  - Soma ponderada;
  - Previsão centrada na média;
- Avaliação utilizando 3 métricas de precisão:
  - MAE: Erro médio absoluto
  - RMSE: Raíz do erro quadrático médio
  - Medida F1

Metodologia - Métricas

- Mean Absolute Error (MAE)

$$MAE = \frac{1}{N}\sum_{i=1}^{N}|y_i - \hat{y}_i|$$

- Root Mean Squared Error (RMSE)

$$RMSE = \sqrt{\sum_{i=1}^{n}\frac{(\hat{y}_i - y_i)^2}{n}}$$

Metodologia - Métricas

- F1 – score
  - Normalmente utilizada para respostas discretas;
  - Considera predições com nota acima de 70% como verdadeiras e abaixo como falsas (se notas variam entre [0,5] então se nota > 3.5 = verdadeiro);
  - Pondera a precisão e o *recall*.

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$\boldsymbol{F1} = 2 \cdot \frac{\mathbf{precision} \cdot \mathbf{recall}}{\mathbf{precision} + \mathbf{recall}}$$

Resultados - Apresentação dos gráficos

Fig. 1 Average MAE achieved by the 15 metrics, when NNs are selected using a similarity threshold and under neighbour THR=0.0

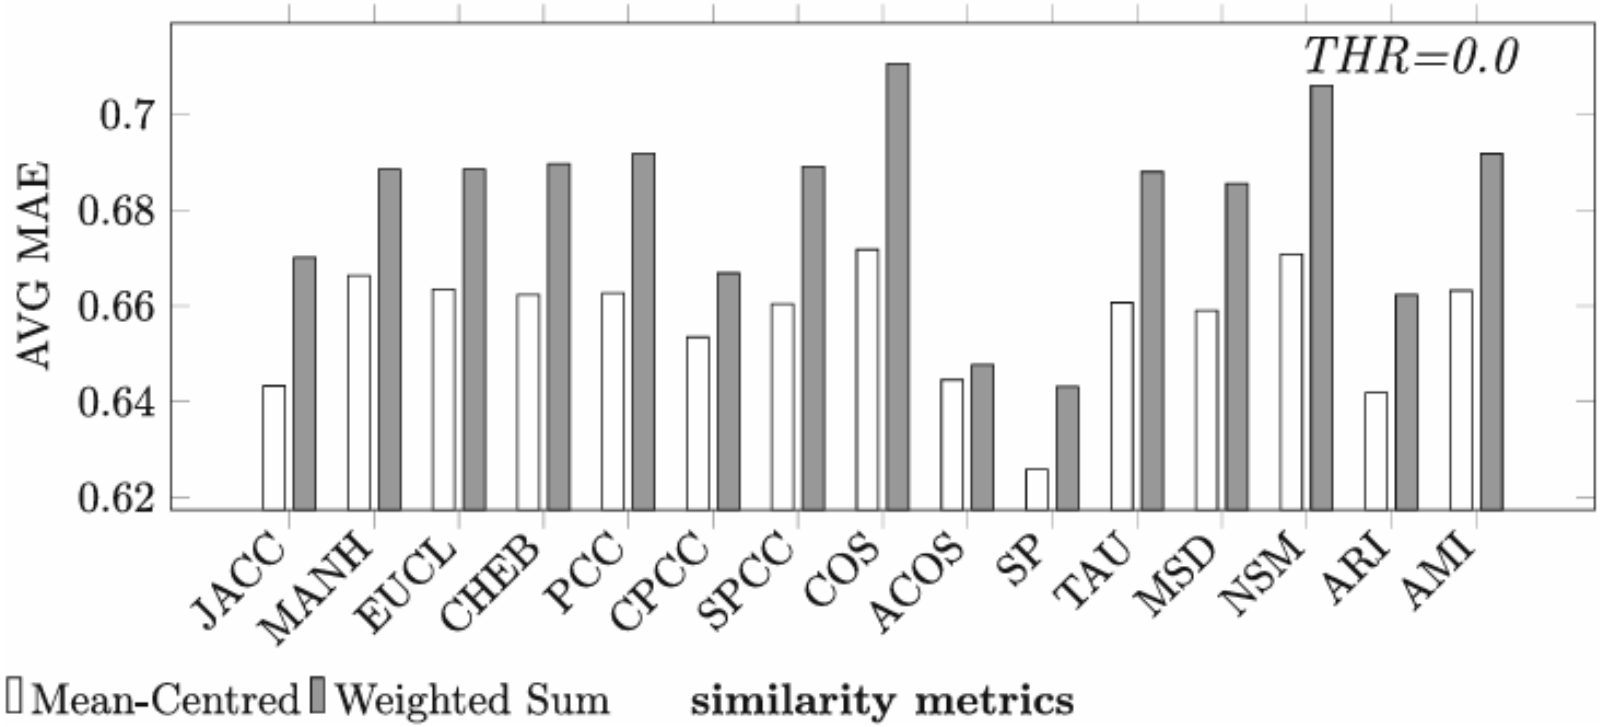

Resultados – Intervalos de resultados

- MAE: entre aproximadamente 0.6 e 0.7
- RMSE: entre aproximadamente 0.95 e 1.15
- F1: entre aproximadamente 0.8 e 0.84

Resultados - Tabelas

- As tabelas (6 e 7) a seguir mostram um resultado das comparações entre as métricas para todas as seleções de vizinho (K = 250 e 500, THR = 0, 0.25 e 0.5);
- Tabela 6 mostra os resultados para a predição feita pela soma ponderada;
- Tabela 7 mostra os resultados para a predição feita pela centralização na média;
- ++ indica o método com melhor resultado;
- + indica métodos que tiveram bons resultados;
  - MAE / RMSE: Erro até 5% acima do melhor;
  - F1: Pontuação até 1% abaixo do melhor.

Resultados - Predição: Soma ponderada

mean-	K=250			K=500			THR=0.0			THR=0.25			THR=0.5		
centred	M	R	F	M	R	F	M	R	F	M	R	F	M	R	F
JACC	++	++	+	++	++	+	+	+	+						
MANH		+	+		+	+		+	+			+	+	+	+
EUCL		+	+		+	+		+	+		+	+	+	+	+
CHEB	+	+	+		+	+		+	+		+	++	+	+	+
PCC								+	+		+				+
CPCC		+	+	+		+	+	+	+		+	+		+	+
SPCC			+			+		+	+		+				+
COS		+	+		+	+		+	+		+	+			+
ACOS						+	+	+	++	+	+	+			+
SP	+	+	+	+	+	+	++	++	+	++	++	+	++	++	+
TAU								+	+		+				
MSD		+	+	+	+	+		+	+		+				
NSM		+	++		+	++		+	+			+			++
ARI	+	+	+	+		+	+	+	+	+	+	+	+		+

Tabela 6
Página 19 do
artigo base [1]

Resultados - Predição: Previsão centrada na média

weighted	K=250			K=500			THR=0.0			THR=0.25			THR=0.5		
sum	M	R	F	M	R	F	M	R	F	M	R	F	M	R	F
JACC	+	++		+	++		+	+							
MANH	+		+		+	+		+		+	+	+	+	+	+
EUCL	+		+		+	+		+		+	+	+	+	+	+
CHEB	+	+	+		+			+		+	+	+	+	+	+
PCC						+		+			+				
CPCC	+	+	+	+	+	+	+	+	+		+	+		+	+
SPCC		+	+			+		+			+	+			+
COS			+		+	+		+				+			+
ACOS	+		+	+		+	+	+	++	+	+	++		+	+
SP	++	+	+	++	+	+	++	++	+	++	++	+	++	++	+
TAU								+	+		+				
MSD	+	+	+	+	+	+		+			+			+	
NSM			++		+	++		+	+			+			++
ARI	+	+		+	+		+	+	+	+	+	+			+
AMI					+			+							

Tabela 7
Página 19 do artigo base [1]

Resultados

- SP se sobressai contra as demais medidas
  - Menor sensibilidade a outliers: Notas extremas não distorcem os resultados de similaridade, o que é vital em matrizes esparsas onde há poucos itens avaliados em comum;
  - Foco em rankings: Utiliza a ordem de preferência em vez de valores brutos, eliminando o viés de usuários muito rigorosos ou muito lenientes na hora de dar a nota;
  - Relações não-lineares: Consegue capturar padrões de similaridade complexos nos dados, ao passo que métricas tradicionais (Cosseno e Pearson) capturam apenas relações lineares.
- Outras métricas como ARI, CPCC e CHEB também figuraram entre os melhores resultados.

Pontos fortes

- Amplitude metodológica: Utiliza múltiplas métricas de precisão, métodos de seleção de vizinhos, abordagens de formulação de cálculo e datasets;
- Resultados independentes das configurações e parâmetros do algoritmo escolhidos para o modelo CF;

Limitações

- Comparação de tempo de execução:
  - Por mais que os autores descrevam a complexidade do cálculo de cada métrica, eles não apresentam nenhum resultado empírico do tempo de execução para exemplificar a magnitude do tempo de processamento.

Possíveis melhorias

- Comparar o tempo de execução de cada métrica.

Direções futuras

- Explorar as métricas mais bem avaliadas em datasets menos esparsos;
- *Adaptar métodos para lidarem com a deriva de interesse;*

Conclusão - Síntese

- Baseado nos experimentos, é recomendada primariamente a inclusão da métrica SP, e secundariamente métricas como ARI, CHEB e CPCC na aplicação de Filtragem Colaborativa sobre matrizes esparsas, abandonando abordagens tradicionais como Pearson ou Cosseno para este nicho;

Conclusão - Síntese

- Quais métricas de similaridade geram os melhores resultados em dados esparsos? **SP, seguido de ARI, CPCC e CHEB**
- Outros parâmetros do algoritmo afetam esse desempenho? **A performance do SP indica ser independente de outros parâmetros**
- A comunidade deve continuar utilizando as métricas mais comuns (Pearson e Cosseno) ou mudar para outras? **Nenhuma das duas métricas apresentaram bons resultados nos experimentos**

Conclusão - Impactos

- Demonstra como métricas de similaridades menos tradicionais podem trazer resultados melhores para algoritmos de recomendação baseados em filtragem colaborativa.

Perguntas?

Links de referência

- GitHub: https://github.com/TiagoMPereira/TP558;
- Quiz: Ciclo 2 - Métricas de similaridade para sistemas de recomendação – Preencher o formulário

Referências

- [1] K. Sgardelis, D. Margaris, D. Spiliotopoulos, and C. Vassilakis, “An evaluation review of user similarity metrics in sparse collaborative filtering datasets,” Int J Data Sci Anal, vol. 20, no. 7, pp. 6665–6693, Jun. 2025, doi: 10.1007/s41060-025-00846-4.
- [2] F. Fkih, “Similarity measures for Collaborative Filtering-based Recommender Systems: Review and experimental comparison,” Journal of King Saud University - Computer and Information Sciences, vol. 34, no. 9, pp. 7645–7669, Oct. 2022, doi: 10.1016/j.jksuci.2021.09.014.
- [3] H. Khojamli and J. Razmara, “Survey of similarity functions on neighborhood-based collaborative filtering,” Expert Systems with Applications, vol. 185, p. 115482, Dec. 2021, doi: 10.1016/j.eswa.2021.115482.

Referências

- [4] Amer, A.A., Abdalla, H.I., Nguyen, L.: Enhancing recommendation systems performance using highly-effective similarity measures. Knowl.-Based Syst. 217, 106842 (2021). https://doi.org/10.1016/j.knosys.2021.106842
- [5] G. Jain, T. Mahara, and K. N. Tripathi, “A Survey of Similarity Measures for Collaborative Filtering-Based Recommender System,” Advances in Intelligent Systems and Computing. Springer Singapore, pp. 343–352, 2020. doi: 10.1007/978-981-15-0751-9_32.
- [6] R. Bojorque, R. Hurtado, and A. Inga, “A Comparative Analysis of Similarity Metrics on Sparse Data for Clustering in Recommender Systems,” Advances in Intelligent Systems and Computing. Springer International Publishing, pp. 291–299, Jun. 29, 2018. doi: 10.1007/978-3-319-94229-2_28.

Obrigado!