TP558 - Tópicos avançados em Machine Learning:

Matrix Factorization-Based Clustering for Sparse Data in Recommender Systems: A Comparative Study

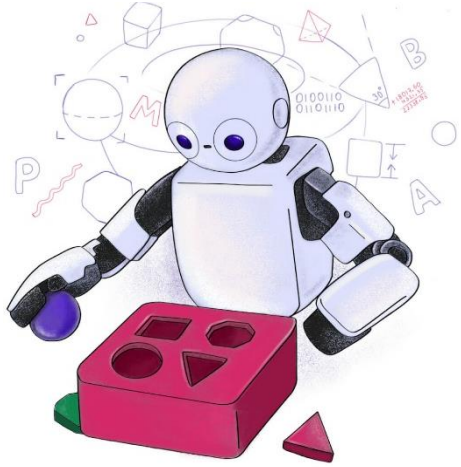

Inatel

Tiago de Morais Pereira
tiago.morais@mtel.inatel.br

Matrix Factorization-Based Clustering for Sparse Data in Recommender Systems: A Comparative Study

- Autores: Rodolfo Bojorque, Remigio Hurtado
- Ano de publicação: 2025
- Local de publicação: Computation (MDPI)
- Data da publicação: 03 set. 2025
- DOI: https://doi.org/10.3390/computation13090213

Contexto

- Sistemas de Recomendação (RS) são fundamentais em plataformas digitais para personalizar conteúdo e engajar usuários em e-commerce e streaming;
- O agrupamento (clustering) reduz a dimensionalidade do problema de recomendação, organizando usuários e itens em segmentos interpretáveis para lidar com sistemas em grande escala.

Objetivo

- Aplicar fatoração de matrizes para encontrar dimensões latentes;
- Avaliar a eficácia de métodos de agrupamento "hard" e "soft";
- Comparar com abordagens de Fatoração de Matrizes Não-Negativas (NMF) e Bayesian NMF.

Hipótese

- Metodologias de Fatoração de Matrizes podem melhorar simultaneamente a qualidade do agrupamento e a performance de recomendações.

Fundamentação teórica - Conceitos

- Agrupamento (clustering):
  - Técnica de aprendizado de máquina Não Supervisionado que organiza os dados brutos em grupos (clusters) baseados em suas semelhanças.

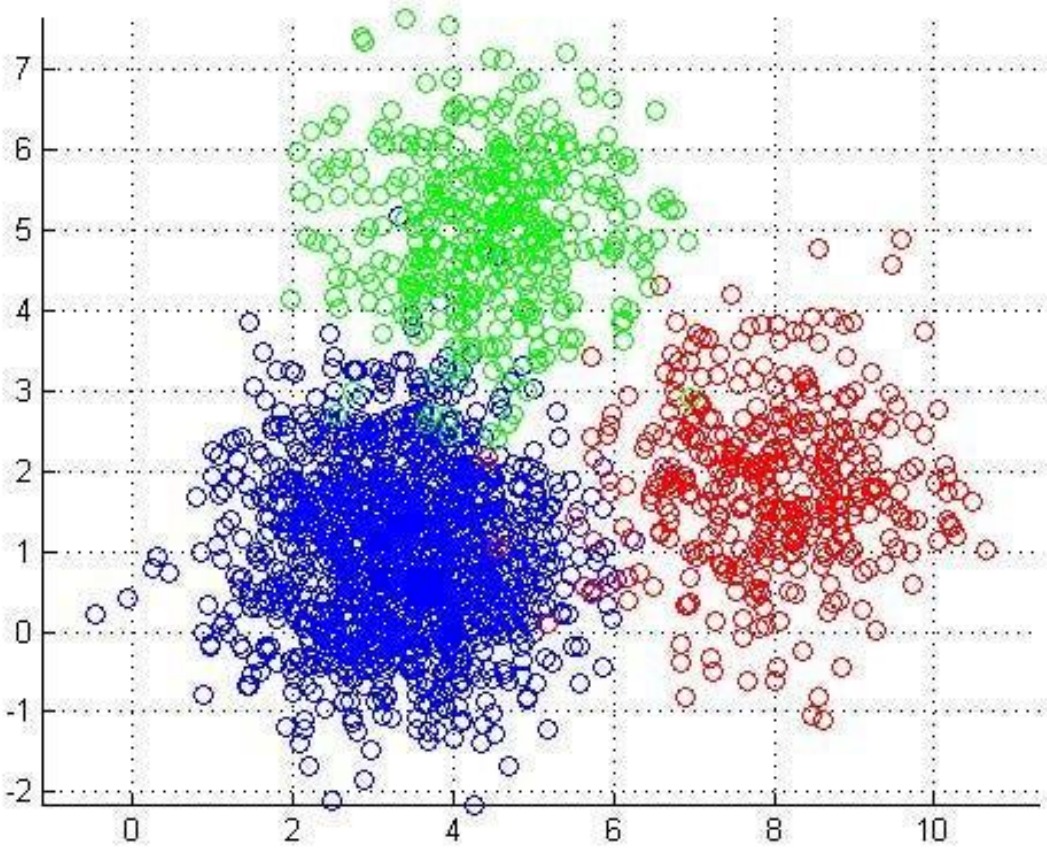

Dísponível em: https://medium.com/@caprioleo.nsa/unraveling-patterns-in-data-a-dive-into-k-means-clustering-and-pca-fe14ea12f4d6. Acesso em 13/04/2026.

Fundamentação teórica - Conceitos

- Hard clustering:
  - Agrupamento onde cada dado pertence única e exclusivamente a um grupo.
  - Modelos mais conhecidos:
    - K-means
    - DBSCAN
    - HDBSCAN

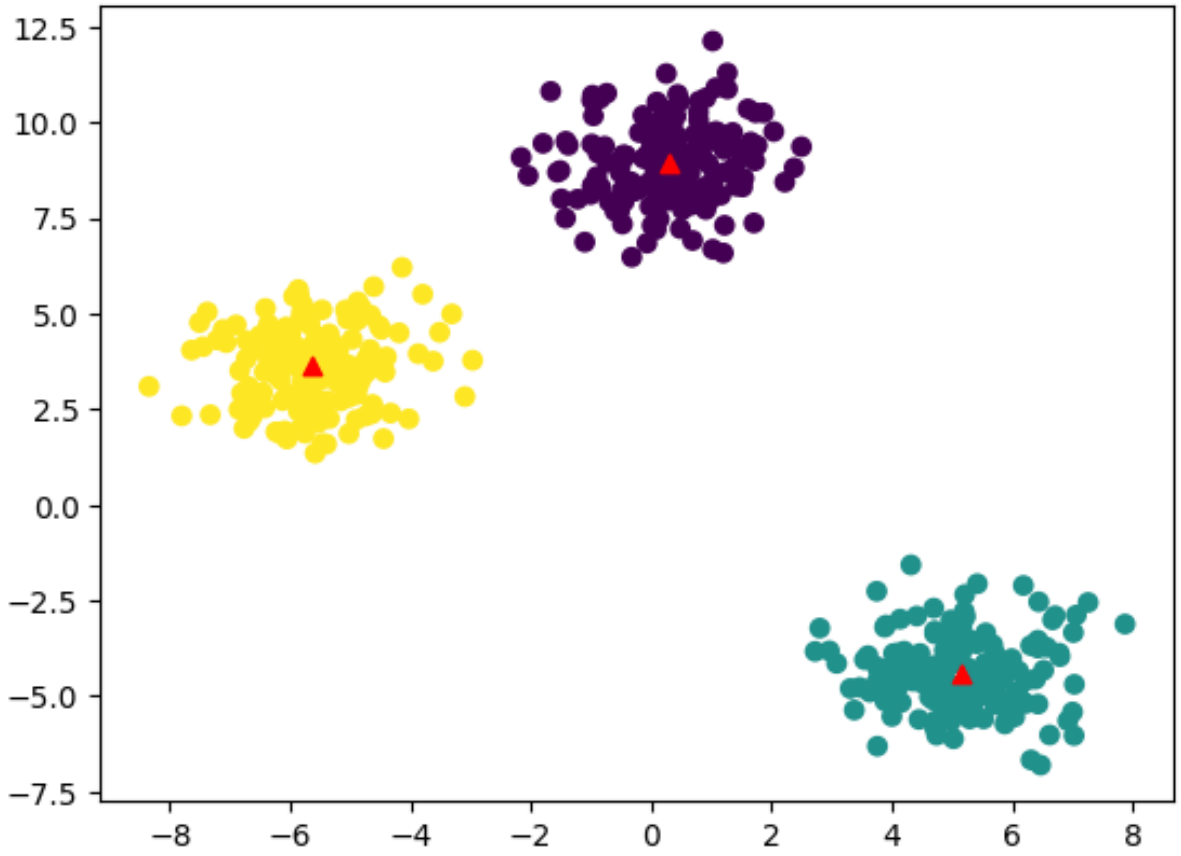

Disponível em: https://www.geeksforgeeks.org/machine-learning/k-means-clustering-introduction/. Acesso em: 13/04/2026.

Fundamentação teórica - Conceitos

- Hard clustering:
  - K-means

$$\arg\min_{\mathbf{S}} \sum_{i=1}^{k} \sum_{\mathbf{x} \in S_i} \|\mathbf{x} - \boldsymbol{\mu}_i\|^2$$

$$c_{j-kmeans} = \frac{\sum_{i=1}^{n} x_i}{\sum_{i=1}^{n}}$$

Fundamentação teórica - Conceitos

- Soft clustering:
  - Agrupamento que permite que um dado pertença a mais de um grupo com intensidades diferentes;
  - Agrupamentos fuzzy, por exemplo, determinam o grau de pertencimento de cada dado em cada cluster.

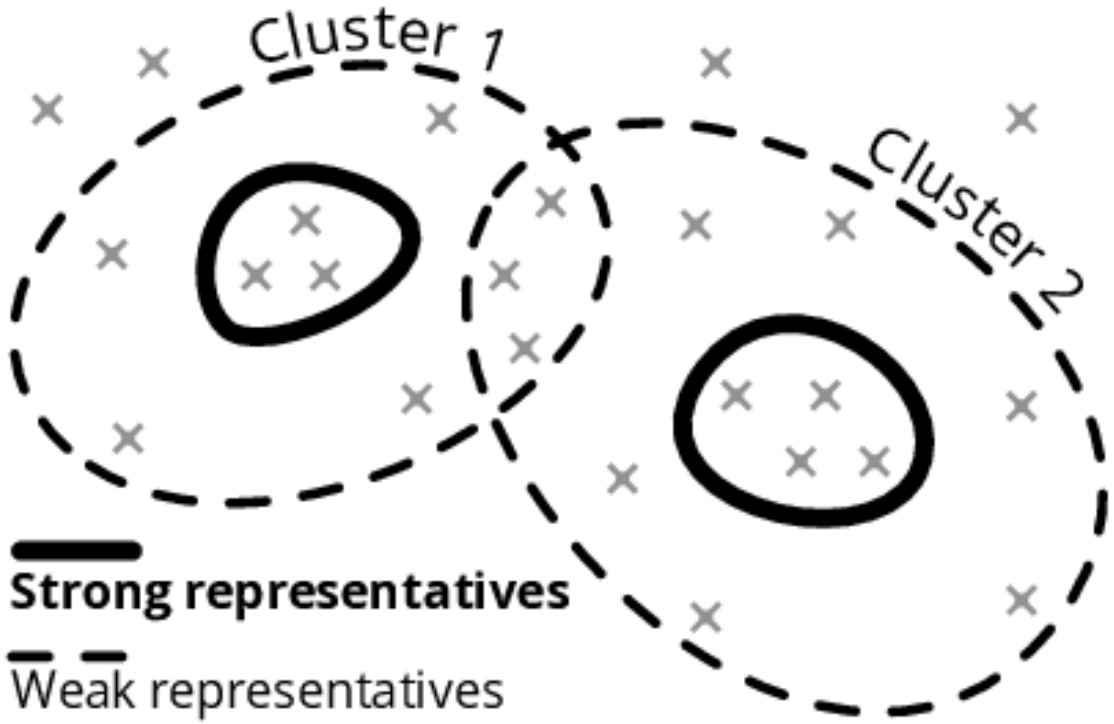

Disponível em: https://www.researchgate.net/profile/Gael-Bernard/publication/333642740/figure/fig6/AS:766744884965379@1559817634470/Ilustration-of-the-soft-clustering-concept.png. Acesso em: 13/04/2026.

Fundamentação teórica - Conceitos

- Soft clustering:
  - Fuzzy C-Means (FCM)

$$J_{c-fcm} = \sum_{j=1}^{c} \sum_{i=1}^{n} \mathcal{U}_{ij}^{a} ||x_i - c_j||^2 \tag{3}$$

where

- n is the number of samples;
- c is the number of clusters;
- $\mathcal{U}_{ij} \in [0, 1]$ represents the membership of the ith sample for the jth cluster;
- c_j is the jth cluster;
- x_i is the ith sample;
- $a \in \mathbb{R}^+$ y $a >= 1$ is the overlapping coefficient. When $a = 1$, the hard-clustering approach is used.

Fundamentação teórica - Conceitos

- Soft clustering:
  - Fuzzy C-Means (FCM)

$$\mathcal{U}_{ij} = \frac{1}{\sum_{k=1}^{c} \left(\frac{||x_i - c_i||^2}{||x_i - c_k||^2} \right)^{2(a-1)}}$$

$$c_{j-fcm} = \frac{\sum_{i=1}^{n} \left(\mathcal{U}_{ij}^{a} \right) x_i}{\sum_{i=1}^{n} \left(\mathcal{U}_{ij}^{a} \right)}$$

Fundamentação teórica - Conceitos

- Fatoração de Matriz
  - Decompõe uma matriz **n x m** em fatores latentes **n x k** e **k x m**;
  - Fatores latentes podem revelar estruturas escondidas, como preferências dos usuários.

?	?	?	**5**
5	**4**	?	?
?	?	**2**	?
?	**1**	?	**1**
?	?	**3**	?

User-Item Matrix R_{N*D}

1.2	0.4
2.2	3.9
1.5	2.4
3.1	1.5
0.4	0.5

User-features Matrix P_{N*K}

*

1.5	2.1	0.3	3.4
0.4	1.2	2.4	0.75

Item-Features Matrix Q_{K*D}

Disponível em: https://builtin.com/articles/matrix-factorization. Acesso em: 13/04/2026.

Fundamentação teórica - Conceitos

- Fatoração de Matriz

	Feature 1	Feature 2
User 1	?	?
User 2	?	?
User 3	?	?
User 4	?	?
User 5	?	?

X

	Item 1	Item 2	Item 3	Item 4	Item 5
Feature 1	?	?	?	?	?
Feature 2	?	?	?	?	?

=

	Item 1	Item 2	Item 3	Item 4	Item 5
User 1	0 ?	3	0 ?	3	0 ?
User 2	4	0 ?	0 ?	2	0 ?
User 3	0 ?	0 ?	3	0 ?	0 ?
User 4	3	0 ?	4	0 ?	3
User 5	4	3	0 ?	4	0 ?

Disponível em: https://github.com/SurhanZahid/Recommendation-System-Using-Matrix-Factorization. Acesso em: 13/04/2026.

Fundamentação teórica - Conceitos

- Fatoração de Matriz Não-Negativa (NMF)
  - Garante que os vetores latentes sejam positivos

$$\min_{P,Q} ||R - P \times Q^T||_F^2 \quad \text{subject to} \quad P \geq 0, \quad Q \geq 0$$

Fundamentação teórica - Conceitos

- Fatoração de Matriz Não-Negativa de Bayes (BNMF)
  - Modelo probabilístico avançado de NMF que introduz interesses positivos e negativos.
  - Utiliza os parâmetros *alpha* (sobreposição) e *beta* (confiança);

$$\gamma_{u,k} = \alpha + \sum_{\{i|r_{u,i} \neq \bullet\}} \lambda_{u,i,k}$$

$$\epsilon^{+}_{i,k} = \beta + \sum_{\{u|r_{u,i} \neq \bullet\}} \lambda_{u,i,k} \cdot r^{+}_{u,i}$$

$$\epsilon^{-}_{i,k} = \beta + \sum_{\{u|r_{u,i} \neq \bullet\}} \lambda_{u,i,k} \cdot r^{-}_{u,i}$$

$$a_{u,k} = \frac{\gamma_{u,k}}{\sum_{j=1...K} \gamma_{u,j}}$$

Fundamentação teórica - Conceitos

- Fatoração de Matriz Não-Negativa de Bayes (BNMF)
  - *alpha* [0,1]: sobreposição dos clusters, quanto mais próximo de 0, menor a sobreposição;
  - *beta* (>1): confiança necessária para dizer que um grupo de usuários gosta ou não de um item;
  - $\lambda_{u,i,k}$ quanto a interação (u,i) pertence ao cluster k;
  - $\gamma_{u,k}$ força do usuário no cluster k;
  - $r^{+}_{u,i}$ e $r^{-}_{u,i}$ intensidade que o usuário gostou ou não de um item;
  - $\epsilon^{+}_{i,k}$ e $\epsilon^{-}_{i,k}$ evidência que o cluster k gosta ou não de um item;
  - $a_{u,k}$ Probabilidade do usuário u ser do cluster k.

Metodologia – Base de dados

- Dataset MovieLens 1M;
- Separação em 20 subconjuntos, cada subconjunto é separado em proporção 80/20 para treino e validação;
- Implementação usando o framework **CF4J**.

Metodologia – Métricas

- Avaliação de clusters:

$$\text{Intra-cluster} = \sum_{k=1}^{K} \sum_{u=1}^{n} ||x_u - c_k||^2$$

Hard clustering

$$\text{Intra-cluster} = \sum_{k=1}^{K} \sum_{u=1}^{n} p_{u,k} ||x_u - c_k||^2$$

Soft clustering

Metodologia - Fluxo

- Comparar a consistência intra-cluster do BNMF com técnicas de agrupamento "hard" e "soft";
- Medir o erro médio absoluto.

Resultados - Consistência intra-cluster

- Bayesian NMF x Soft clustering

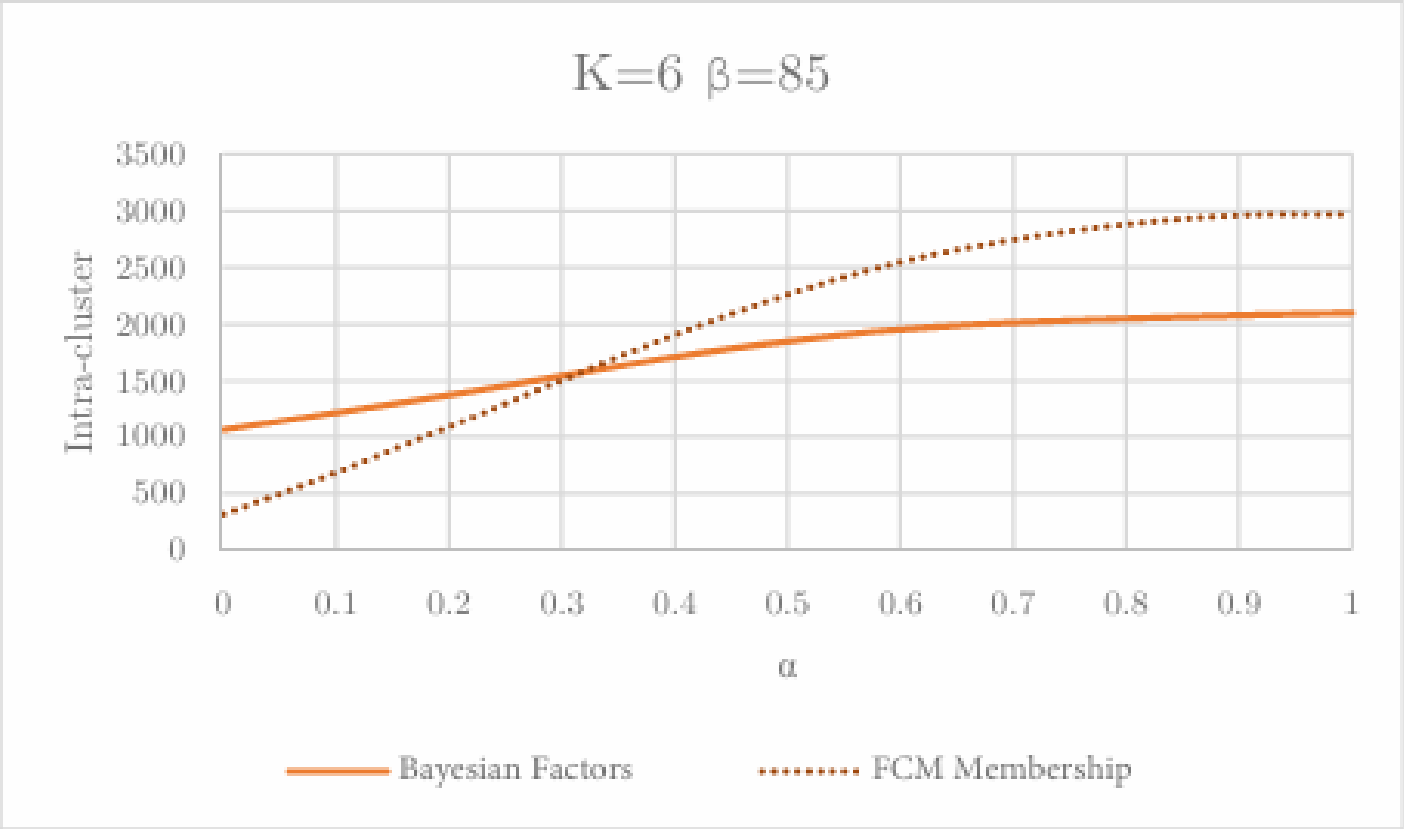

k	a	FCM Over-lapping	α	Bayesian Overlapping
6	1.1	0.964	0	0.823
6	1.2	0.922	0.1	0.792
6	1.3	0.875	0.2	0.772
6	1.4	0.825	0.3	0.743
6	1.5	0.776	0.4	0.706
6	1.6	0.727	0.5	0.644
6	1.7	0.681	0.6	0.609
6	1.8	0.638	0.7	0.572
6	1.9	0.597	0.8	0.549
6	2	0.56	0.9	0.531
6	2.1	0.527	1	0.506

Resultados - Consistência intra-cluster

- Bayesian NMF x Hard clustering

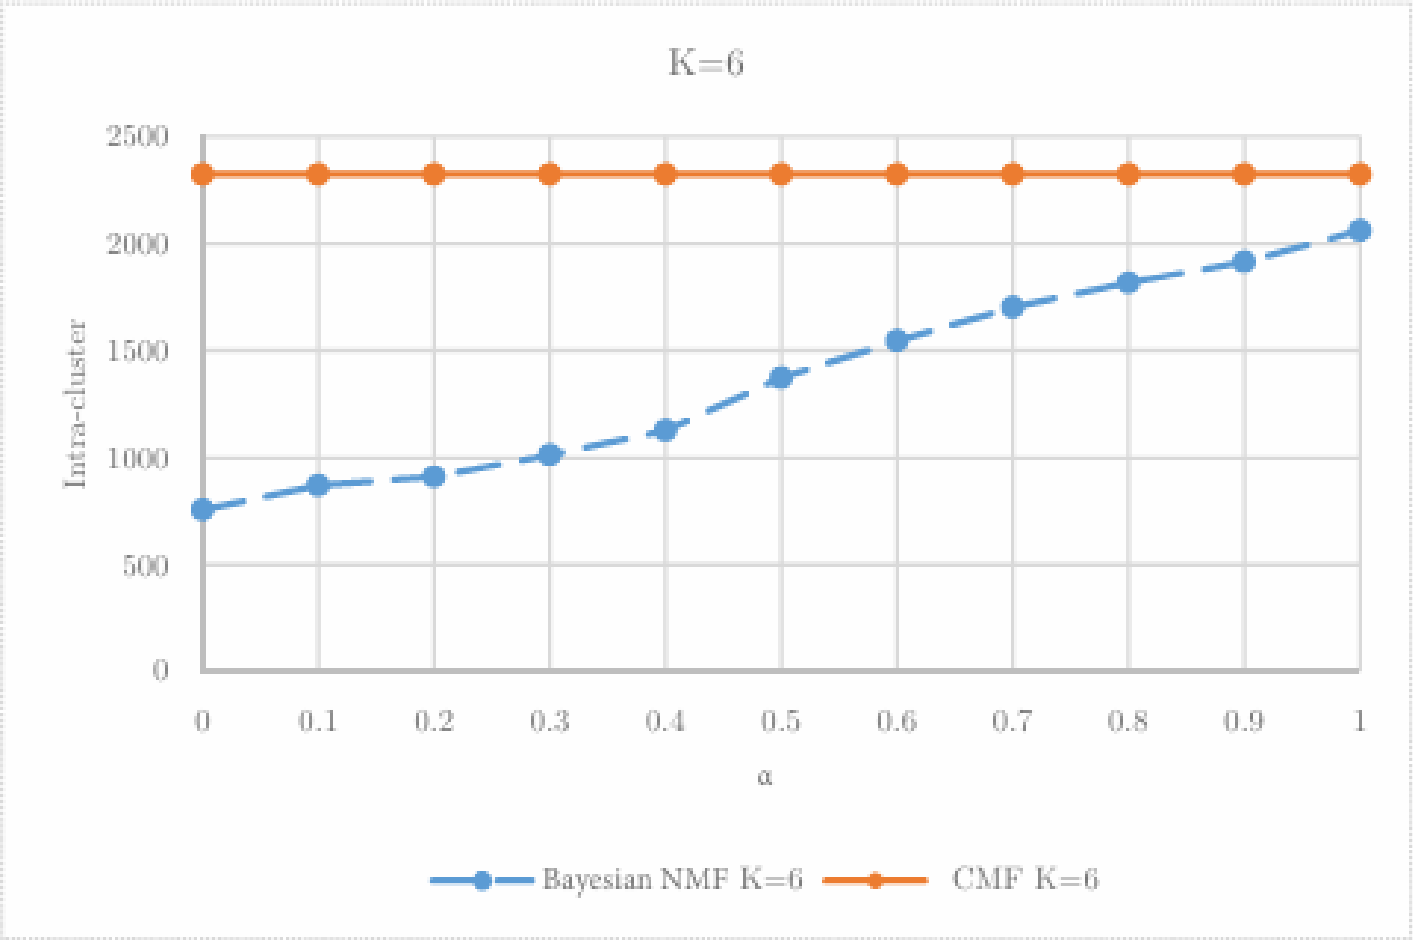

Resultados - Consistência intra-cluster

- K-means

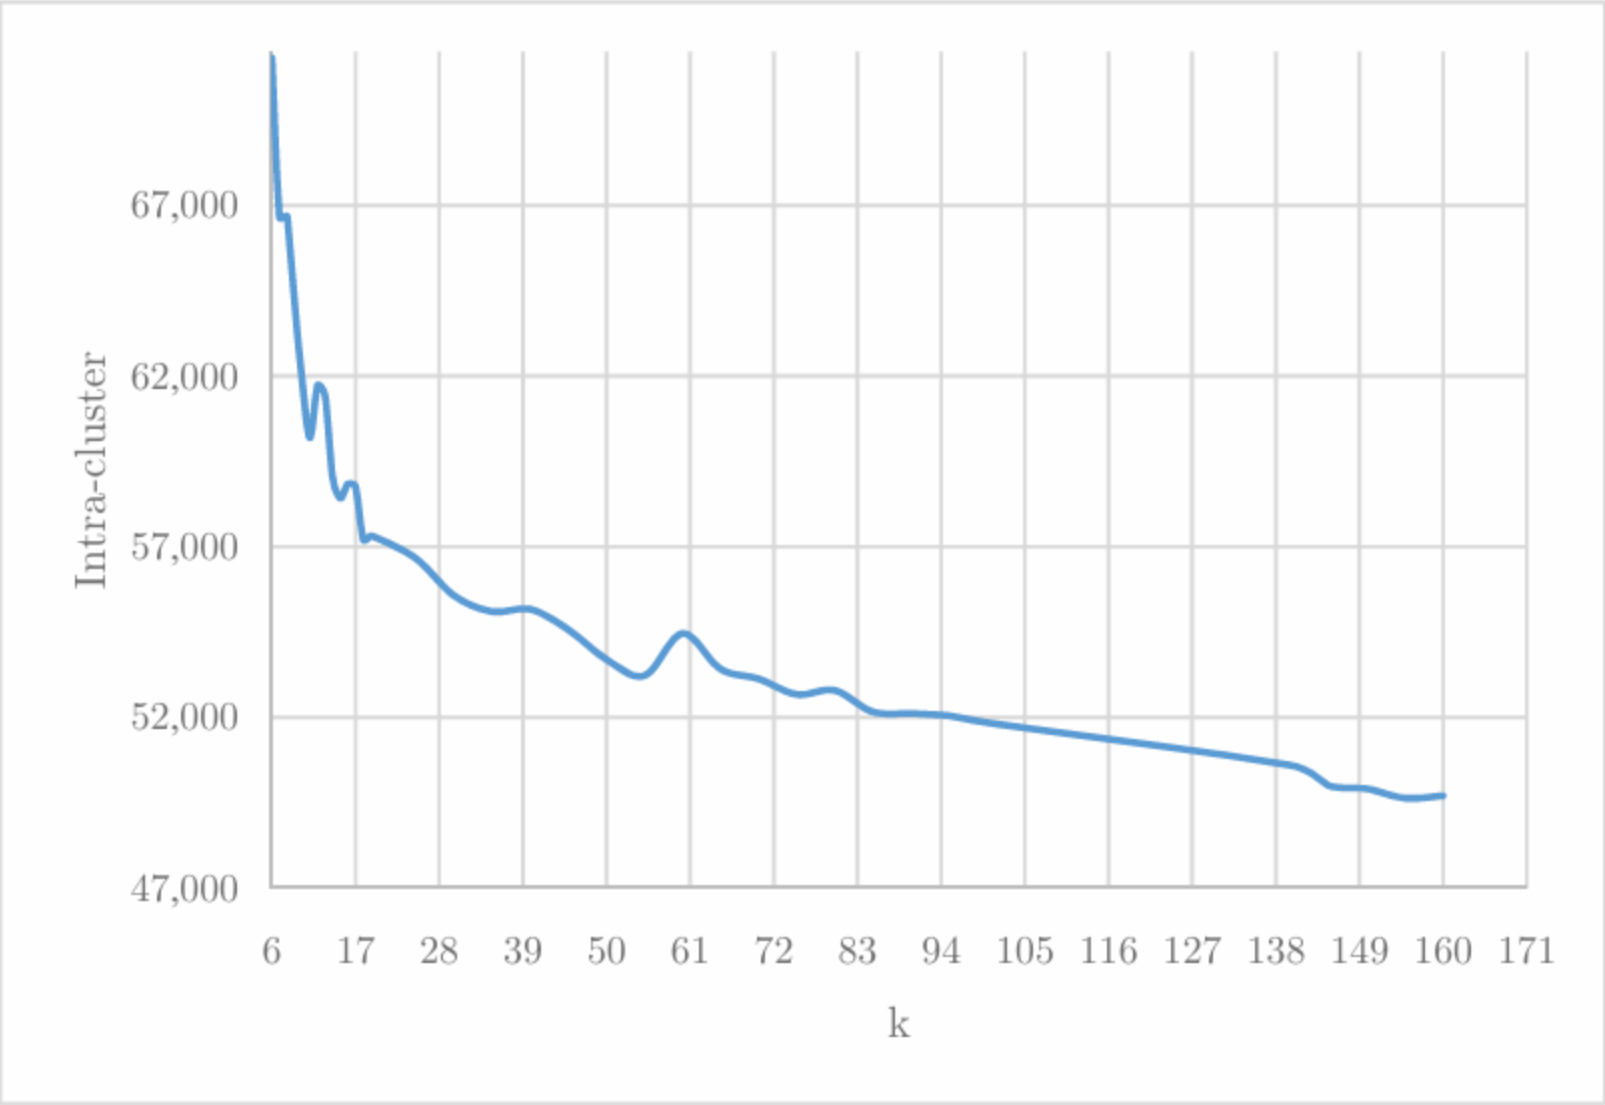

Resultados – Consistência intra-cluster

- Comparando o Bayesian NMF com soft e hard clustering (FCM e CMF) o BNMF apresenta menores distâncias intra-cluster, logo, maior consistência dos clusters;
- À medida que *alpha* aumenta a consistência do cluster diminui, pois são aceitos mais dados em um grupo;
- Comparando com K-means, todos métodos apresentaram maior consistência intra-cluster.

Resultados – Erro de predição - MAE

- Bayesian NMF

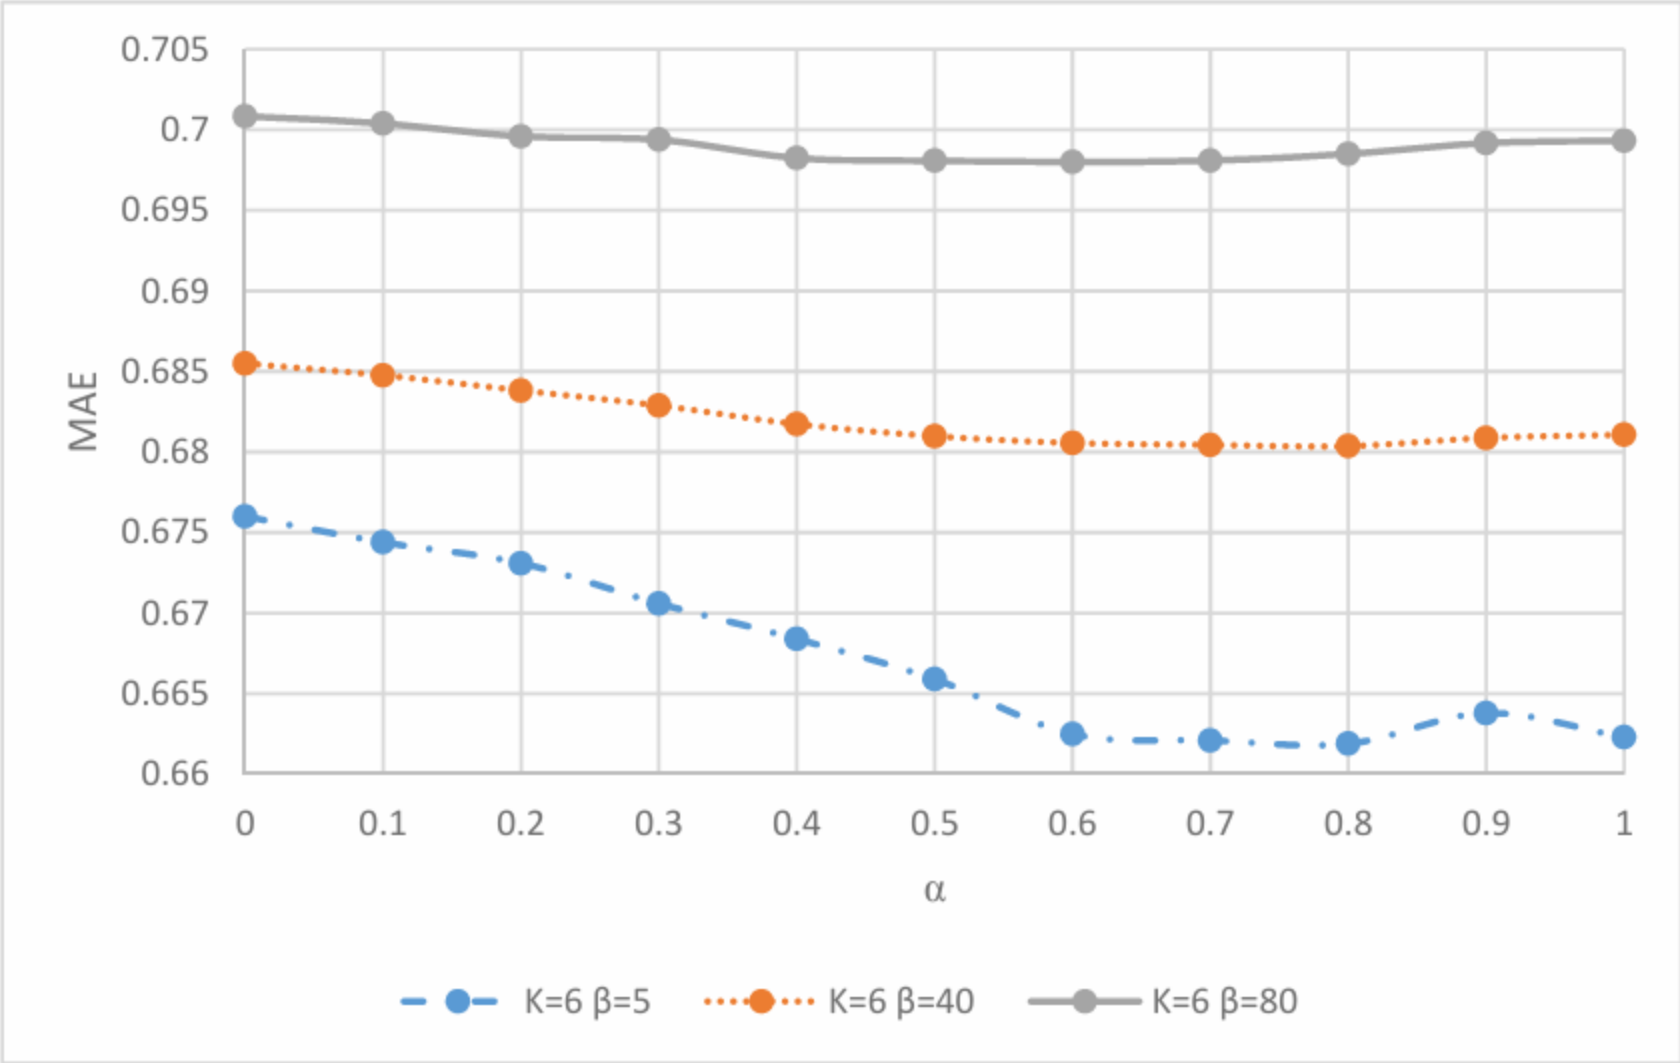

Resultados – Erro de predição - MAE

- K-means

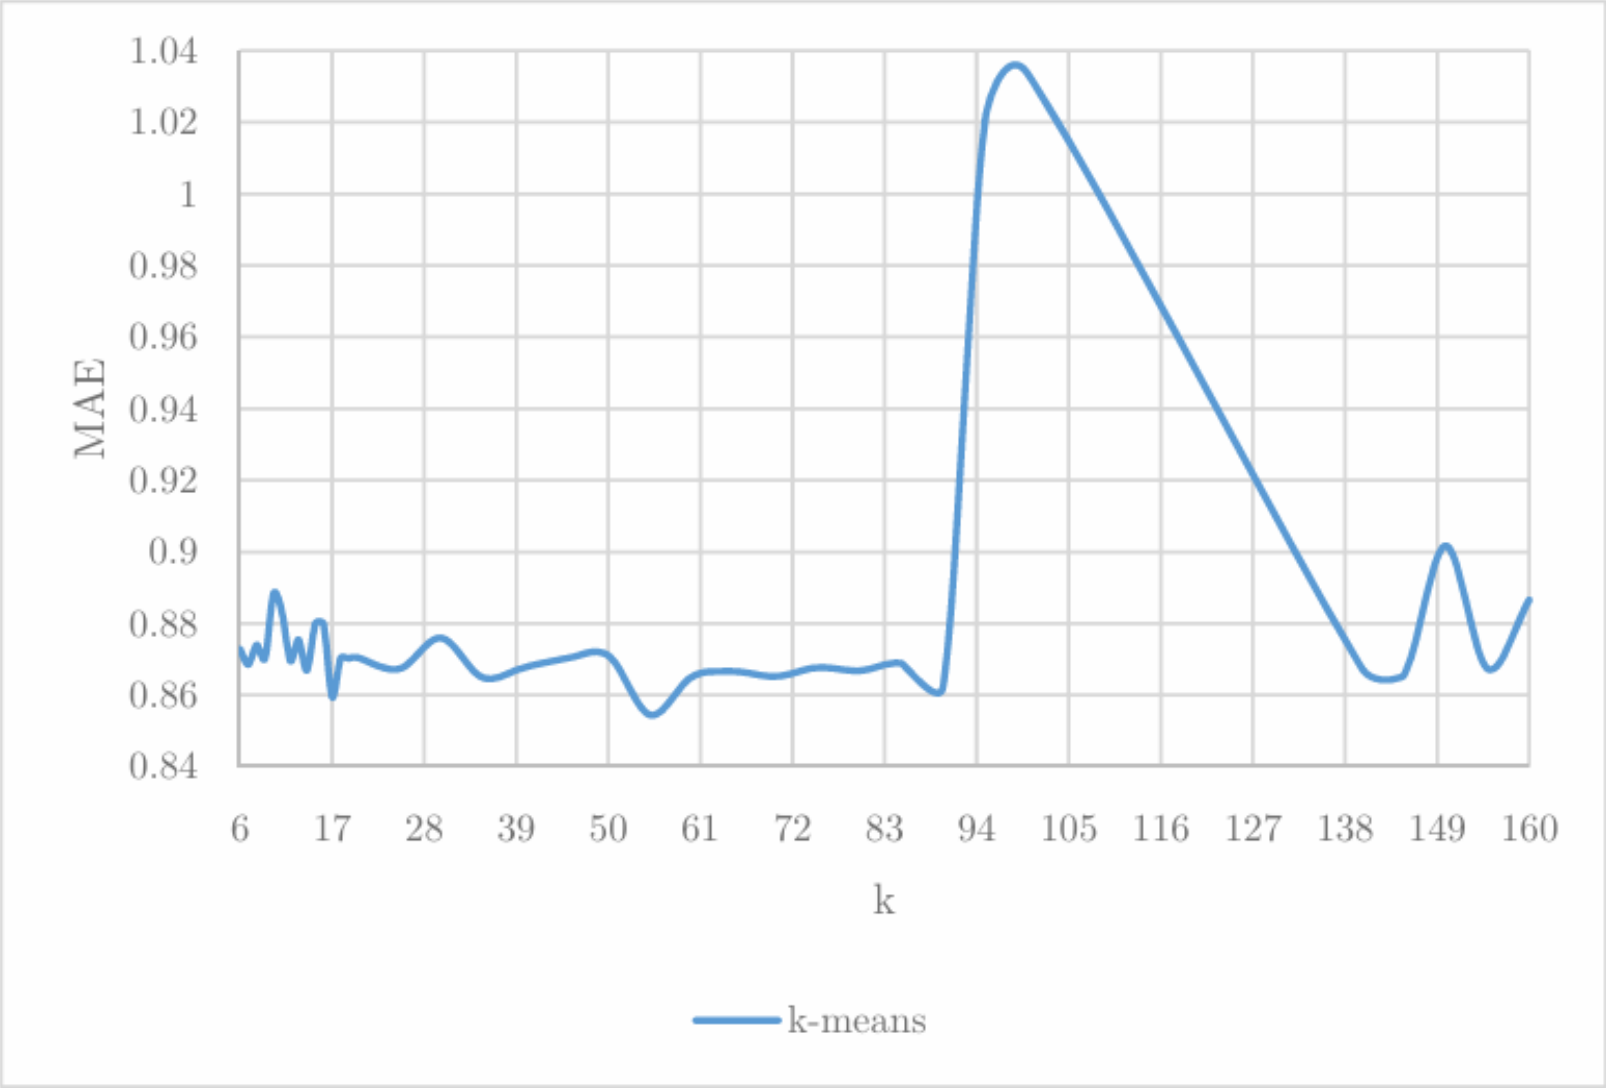

Resultados – Consistência intra-cluster

- **Não foi explicitado qual modelo de recomendação foi utilizado em conjunto com o K-means;**
- O erro da fatoração de matriz tende a ser menor que o erro do K-means + modelo de recomendação.

Resultados - Destaques

- Bayesian NMF tem melhores clusters e melhor poder preditivo do que métodos tradicionais (K-means e Common Matrix Factorization);
- Acurácia preditiva requer ajuste de parâmetros (*alpha* e *beta*);
- Soft clustering melhora a acurácia, mas diminui a coesão dos clusters enquanto hard custering melhora a coesão dos clusters em troca de uma menor acurácia.

Pontos fortes

- Mostra a divergência pouco intuitiva entre coesão intra-cluster e poder preditivo, quando usados modelos de fatoração de matriz;
- Apresenta soft clustering como alternativa viável aos métodos de agrupamento tradicionais.

Limitações

- Artigo pouco explicativo. Equações sem explicação. Utiliza um software, mas não descreve as configurações do mesmo;
- Falta de comparação em relação ao tempo de execução;
- Desconsidera métricas de separação inter-cluster;
- Define poucos valores discretos para *beta.*

Possíveis melhorias

- Adicionar métricas inter-cluster;
- Explicitar o tempo de processamento;
- Explicitar os parâmetros usados no software de experimento;
- Otimizar hiperparâmetros (como *alpha* e *beta* do BNMF e *a* do FCM).

Conclusão - Síntese

- BNMF supera os métodos tradicionais;
- Trade-off entre coesão intra-cluster e precisão;

Perguntas?

Links de referência

- GitHub: https://github.com/TiagoMPereira/TP558;
- Quiz: Ciclo 3 - Agrupamento com fatoração de matrizes – Preencher o formulário

Referências

- [1] R. Bojorque and R. Hurtado, “Matrix Factorization-Based Clustering for Sparse Data in Recommender Systems: A Comparative Study,” Computation, vol. 13, no. 9, p. 213, Sep. 2025, doi: 10.3390/computation13090213.
- [2] J. Bobadilla, R. Bojorque, A. Hernando Esteban, and R. Hurtado, “Recommender Systems Clustering Using Bayesian Non Negative Matrix Factorization,” IEEE Access, vol. 6, pp. 3549–3564, 2018, doi: 10.1109/access.2017.2788138.

Obrigado!