TP558 - Tópicos avançados em Machine Learning:

Two-Tower Structure Recommendation Method Fusing Multi-Source Data

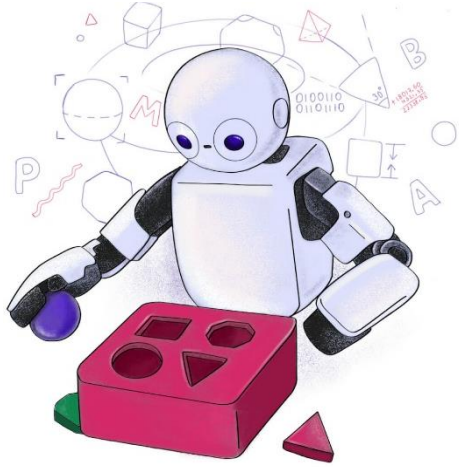

Inatel

Tiago de Morais Pereira
tiago.morais@mtel.inatel.br

Two-Tower Structure Recommendation Method Fusing Multi-Source Data

- Autores: Yaning Su, Yaning Su e Zhiyong Zhang
- Ano de publicação: 2025
- Local de publicação: MDPI Electronics (2025)
- Data da publicação: 02 mar. 2025
- DOI: https://doi.org/10.3390/electronics14051003
- Y. Su, Y. Li, and Z. Zhang, “Two-Tower Structure Recommendation Method Fusing Multi-Source Data,” Electronics, vol. 14, no. 5, p. 1003, Mar. 2025, doi: 10.3390/electronics14051003.

Contexto

- Sistemas de recomendação desempenham um papel vital em áreas como e-commerce, mídias sociais e plataformas de conteúdo;
- Modelos de aprendizado profundo para finalidade de processamento de linguagem natural (BERT) e redes neurais recorrentes (LSTM), são ferramentas poderosas para compreender a **semântica de textos** e capturar as **dependências temporais** dos dados.

Problemas da área

- Métodos convencionais (filtragem colaborativa e recomendação baseada em conteúdo) enfrentam dificuldades com **dados esparsos** e falham em capturar a **dinâmica e a diversidade dos interesses** dos usuários ao longo do tempo;
- Os modelos existentes não conseguem integrar efetivamente dados de múltiplas fontes (como características de usuários e dos itens simultaneamente).

Motivação

- Fornecer aos usuários serviços de recomendação mais inteligentes, precisos e compreensíveis;
- Utilizar de forma eficiente dados textuais como descrições de itens e encontrar padrões a partir dos comentários dos usuários;
- Fundir o poder do modelo BERT (para extrair a semântica) com a rede LSTM (para rastrear o histórico sequencial de interações) para modelar o comportamento do usuário.

Objetivo

- Integrar com sucesso múltiplas fontes de dados (comentários, detalhes de produtos e históricos de interação);
- Propor o modelo BERT-LSTM Dual-Tower Recommendation Method for Sequential Feature Extraction (**BLDRM-SFE**);
- Extrair com maior precisão os interesses multidimensionais e as características emocionais dos usuários;
- Aumentar significativamente a precisão e a personalização da lista de recomendações.

Hipótese

1. A integração eficaz de múltiplas fontes de informação melhora o desempenho do sistema na captura dos interesses do usuário;
2. A análise profunda de sentimentos (*user review*) permite explorar as tendências emocionais dos usuários com maior precisão.

Fundamentação teórica - BERT

- Bidirectional Encoder Representations from Transformers
- Modelo de linguagem pré-treinado;
- Criado para compreensão de linguagem natural (NLP);
- Analisa palavras considerando o que vem antes e depois na frase (Bidirecional);
- Pode ser usado para geração de embeddings semânticos.

Fundamentação teórica - LSTM

- Rede neural recorrente (RNN);
- Capturar dependências de curto e longo prazo;
- Células de memória que armazenam informações ao longo do tempo;
- O estado oculto (hidden state) representa o conhecimento aprendido em cada passo da sequência.

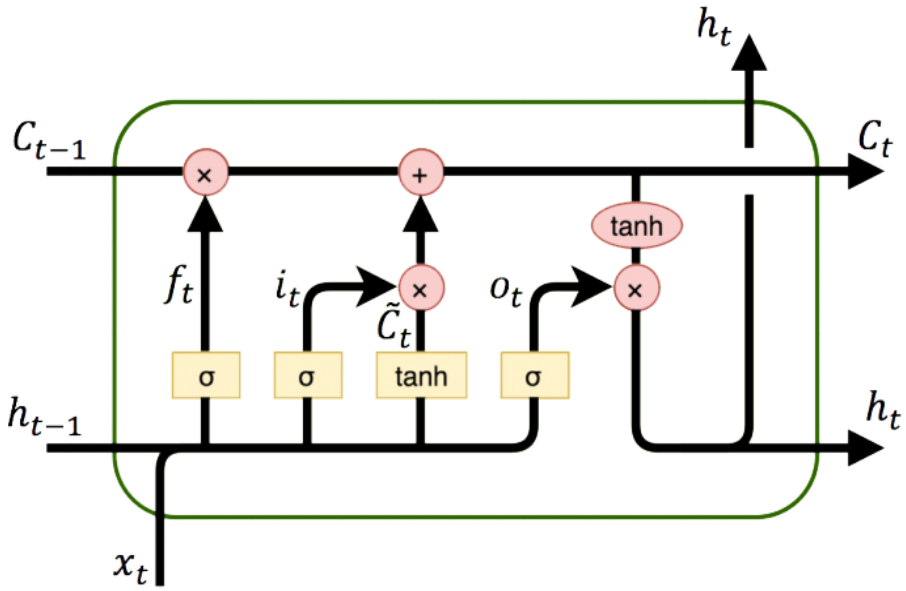

Fundamentação teórica - Two-Tower Network

- Arquitetura de recomendação composta por duas redes neurais independentes: User Tower e Item Tower;
- Aprender embeddings vetoriais de usuários e itens no mesmo espaço latente, permitindo medir similaridade entre eles;

Fundamentação teórica - Two-Tower Network

- User Tower: recebe informações do usuário (histórico, preferências, contexto);
- Item Tower: recebe características do item (categoria, descrição, atributos);
- Cada torre gera um embedding denso representando usuário e item;
- A recomendação é feita calculando a similaridade entre os embeddings.

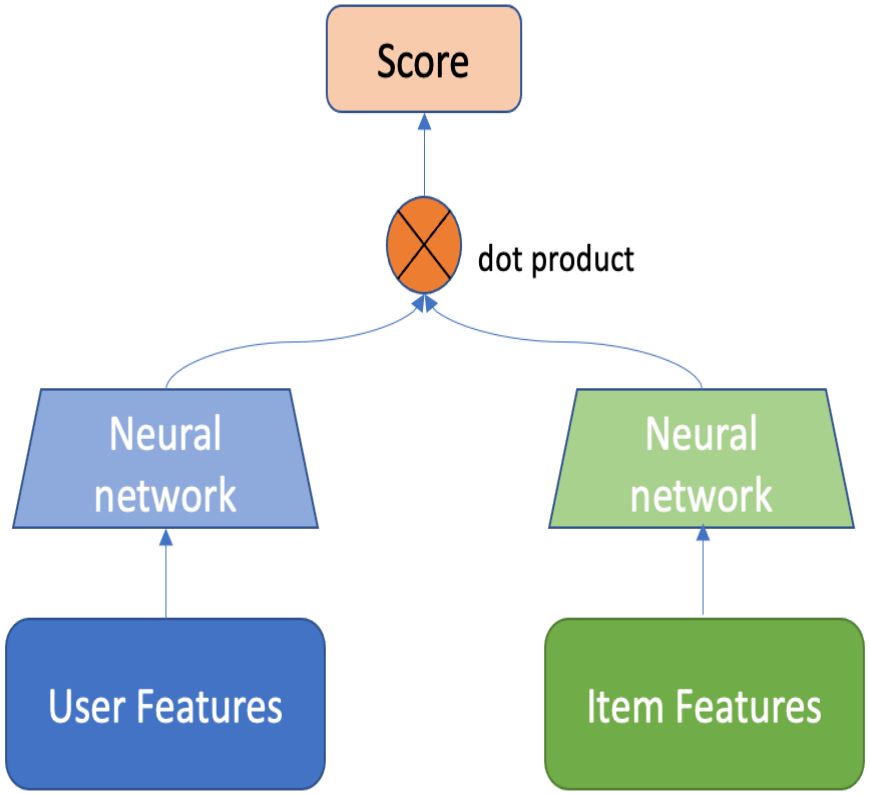

Fundamentação teórica - Trabalhos relacionados

- **BERT4Rec**: converte a sequência de comportamento do usuário em entrada para o BERT para capturar dependências temporais e contexto entre usuário e item;

- **PRM** (Personalized Re-ranking Model): modelo de reordenação que utiliza métodos learning-to-rank para melhorar relevância e personalização dos itens;

Fundamentação teórica - Trabalhos relacionados

- **BST** (Behavior Sequence Transformer): modelo de deep learning para processamento da sequência de cliques do usuário. Modela comportamento sequencial em cenários como e-commerce e prever maior probabilidade de interesse;

- **ComiRec** (Controllable Multi-Interest Recommendation): modelo que captura diferentes preferências e as combina para gerar recomendações Top-K mais diversificadas e precisas.

Fundamentação teórica - BLDRM-SFE

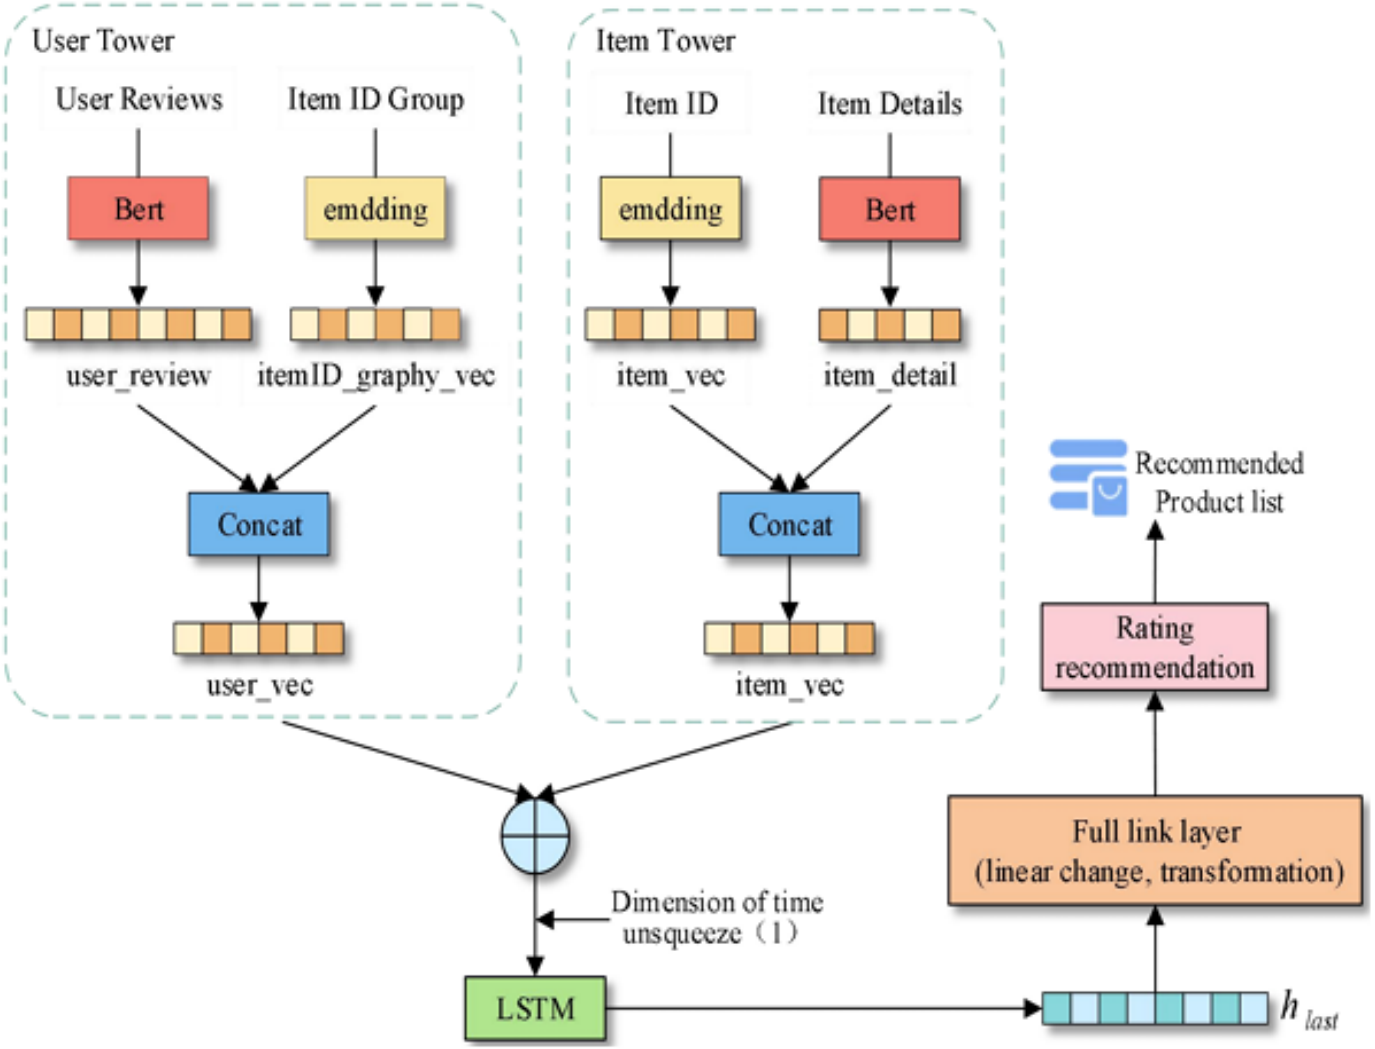

Figure 1. Overall architecture diagram of the method.

Fundamentação teórica - BLDRM-SFE

- BERT-LSTM Dual-Tower Recommendation Method for Sequential Feature Extraction;
- Torre do Usuário:
  - Comentários (User Reviews) passam pelo BERT para virar vetores semânticos;
  - Histórico de Interações (Item ID Group) passa pela camada de Embedding;
  - Ambos são unidos (Concat) formando o vetor final do usuário.
- Torre do Item (Item Tower):
  - Os Detalhes do Item passam pelo BERT;
  - ID do Item passa pelo Embedding;
  - Ambos são unidos (Concat) para criar o vetor final do item

Fundamentação teórica - BLDRM-SFE

- Os vetores do usuário e do item saem de suas respectivas torres e são concatenados em um único vetor combinado;
- LSTM:
  - Dimensão temporal é adicionada ao vetor concatenado;
  - A LSTM processa a sequência de interações passadas e extrai apenas o último estado oculto.
- O dado final passa por uma camada totalmente conectada para prever a nota de avaliação do usuário para aquele item;
- Ordenamento de itens.

Fundamentação teórica - BLDRM-SFE

Item ID and item ID grouping obtain the corresponding embedding vector through the embedding layer. For a single item ID, its embedding vector can be expressed as follows.

$$e_{\text{item}} = E_{\text{item}}\left[id_{\text{i}}\right] \tag{3}$$

Here, E_{item} is the item embedding matrix and id_{i} is the unique identifier of the item.

For item ID group $G = \{i_1, i_2, i_3, \ldots\ldots, i_k\}$, we can compute the average of its embedding vectors:

$$e_{\text{group}} = \frac{1}{k}\sum_{j=1}^{k} E_{\text{item}}\left[id_{i_j}\right] \tag{4}$$

Here, k is the number of item IDs in the group.

The review word vector $v_{\text{review}} \in \mathbb{R}^{d_1}$ and the item ID group embedding $e_{\text{group}} \in \mathbb{R}^{d_2}$ are concatenated into the user vector v_{user}. The detail word vector $v_{\text{detail}} \in \mathbb{R}^{d_3}$ and the item ID embedding $e_{\text{item}} \in \mathbb{R}^{d_4}$ are concatenated into the item vector v_{item}:

$$v_{\text{user}} = v_{\text{review}} \oplus e_{\text{group}} \in \mathbb{R}^{d_1+d_2} \tag{5}$$

$$v_{\text{item}} = v_{\text{detail}} \oplus e_{\text{item}} \in \mathbb{R}^{d_3+d_4} \tag{6}$$

Here, $\mathbb{R}^d$ denotes a real vector space of dimension d, that is, contains all real vectors of length d.

Fundamentação teórica - CONTRAST

- Modelo de controle criado para comparar com o BLDRM-SFE;
- Arquitetura idêntica à do BLDRM-SFE;
- As características sequenciais (IDs individuais e o histórico de grupos de IDs) são totalmente removidas, deixando o modelo operar apenas com as entradas de texto;
- Objetivo: Avaliar qual é o impacto específico das informações de sequência no desempenho geral do sistema.

Table 1. Comparison of experimental models.

Models	Model Structure	Text Input	Sequence Input	Output	Major Difference
BERT4Rec [36]	BERT+ Bidirectional Self-attention	No	Yes	Probability distribution	BERT is used to process the user behavior sequence, and position encoding is used to capture temporal information.
PRM [37]	Feature extraction module+Transformer encoding module+score prediction module	No	Yes	A reordered list of items	Optimize the initial recommendation list by personalized reranking.
BST [38]	Embedding + Transformer + MLP + Loss function	No	Yes	Probability value	Modeling user click sequence through deep learning structure.
ComiRec [39]	Embedding Layer+Multi-Interest Extraction Module+Aggregation Module	No	Yes	Rank score Score	It captures user's multiple interests and aggregates items for recommendation.
BLDRM-SFE	BERT+LSTM+ Fully connected layer	Yes	Yes	Rating prediction	BERT was used for semantic analysis, and LSTM was combined to capture temporal features for rating prediction.
CONTRAST	BERT+LSTM+ Fully connected layer	Yes	No	Rating prediction	Sequence input is removed compared with BLDRM-SFE.

Metodologia – Base de dados

- Amazon Review Data (Music):
  - Mais de 100.000 avaliações com feedbacks;
  - Mais de 10.000 usuários
- Yelp Dataset: Uma base massiva abrangendo diversas áreas de consumo local (restaurantes, salões, serviços de reparo):
  - Aproximadamente 8 milhões de avaliações
- Divisão para Treinamento: 80% para treino e 20% para teste
- Amostragem estratificada para garantir que a distribuição de comportamento dos usuários fosse consistente, evitando vieses e vazamento de dados.

Metodologia – Base de dados

- As avaliações foram agrupadas pelo ID do usuário, unificando todos os comentários de uma mesma pessoa para reduzir ruídos e preservar seus interesses multidimensionais;
- Os identificadores únicos dos itens foram mapeados para um espaço vetorial de baixa dimensão (*embedding*);
- Construção do histórico (Item ID Group).

Metodologia – Parâmetros

- Batch size: 128;
- Número de épocas: 3;
- Early Stopping ativo;
- Python 3.7;
- CUDA 11.3.

Métrias

- Normalized discounted cumulative gain (NDCG@k)
  - Avaliar a qualidade do ranqueamento dos itens relevantes dentro da lista de recomendação gerada;

$$NDCG@k = \frac{DCG@k}{IDCG@k}$$

$$DCG@k = \sum_{i=1}^{n} \frac{2^{rel_i} - 1}{\log_2 (i+1)}$$

  - Prioriza sistemas que colocam os itens de maior interesse do usuário nas primeiras posições do ranqueamento.

Métrias

- Hit Ratio(HR@k)
  - Verifica se a lista de recomendação contém os itens de interesse, independente da posição. Calcula a proporção de projeções corretas;

$$HR@k = \frac{1}{N} \sum_{i=1}^{N} hits(i)$$

Métrias

- Mean Reciprocal Rank (MRR)
  - Analisa a posição na qual o primeiro item relevante aparece na lista de recomendação;

$$\text{MRR} = \frac{1}{U} \sum_{u=1}^{U} \frac{1}{rank_i}$$

  - Mede a rapidez com que um usuário encontra o que procura.

Resultados – Amazon Review Data - Music

Table 2. Experimental results on Amazon Review Data-Music, where the optimal results of each metric under different datasets are shown in bold and the suboptimal results are underlined.

	NDCG@5	NDCG@10	HR@5	HR@10	MRR
BERT4Rec	0.5720	0.6519	0.5363	0.6128	0.5127
PRM	0.4387	0.5196	0.4047	0.4926	0.3742
BST	0.4172	0.4723	0.3879	0.4423	0.3494
ComiRec	0.5048	0.6382	0.4841	0.5213	0.4536
BLDRM-SFE	**0.6759**	**0.7327**	**0.6441**	**0.7187**	**0.5676**
CONTRAST	<u>0.6274</u>	<u>0.6892</u>	<u>0.6037</u>	<u>0.6721</u>	<u>0.5248</u>

Resultados – Yelp dataset

Table 3. Experimental results on Yelp dataset, the optimal results of each index under different datasets are shown in bold, and the suboptimal results are underlined.

	NDCG@5	NDCG@10	HR@5	HR@10	MRR
BERT4Rec	0.5219	0.5970	0.4820	0.5626	0.4243
PRM	0.3794	0.4503	0.3504	0.4139	0.3391
BST	0.3539	0.4022	0.3266	0.3917	0.3128
ComiRec	0.4436	0.5195	0.4323	0.4953	0.3871
BLDRM-SFE	**0.6314**	**0.6976**	**0.6124**	**0.6885**	**0.5323**
CONTRAST	<u>0.5848</u>	<u>0.6520</u>	<u>0.5566</u>	<u>0.6375</u>	<u>0.4707</u>

Resultados

- Em ambos datasets o modelo BLDRM-SFE teve os melhores resultados, em todas métricas;
- Em todos os cenários o modelo de controle CONTRAST ficou em segundo lugar;
- BLDRM-SFE > CONTRASR valida a hipótese de que análise semântica somado ao comportamento sequencial aumenta a eficácia;
- Valores de @10 superiores aos de @5, o que mostra que os modelos são melhores quanto mais recomendam.

Resultados - Comparação com a literatura

Table 4. Comparison of model experimental data with the other literature.

Model	Dataset	NDCG@5	NDCG@10	HR@5	HR@10	MMR
BLDRM-SFE	Amazon Review Data-Music	0.6759	0.7327	0.6441	0.7187	0.5676
	Yelp Dataset	0.6314	0.6976	0.6124	0.6885	0.5323
CONTRAST	Amazon Review Data-Music	0.6274	0.6892	0.6037	0.6721	0.5248
	Yelp Dataset	0.5848	0.6520	0.5566	0.6375	0.4707
[40]	Adressa	/	0.338	/	0.688	0.315
[41]	Yelp Dataset	/	0.42	/	0.82	/
[42]	MovieLens-1M	0.5339	0.5251	0.5315	0.5722	/
	Yelp Dataset	0.6163	0.6179	0.6655	0.6933	/
	Goodreads	0.3904	0.4832	0.4846	0.5032	/
[43]	Gawalla	/	0.1618	/	0.3119	/
	Movielens-10M	/	0.0955	/	0.2147	/
	Tmall	/	0.0727	/	0.1536	/
[44]	Tourism	/	/	0.696	0.633	/
	MovieLens	/	/	0.115	0.124	/
	Grocery&Food	/	/	0.162	0.164	/

Note: In the table, "/" indicates that there is no experimental data for the corresponding evaluation standard in the literature.

Resultados - Comparação com a literatura

- [40] SNRBERT: É um sistema de recomendação de notícias baseado em sessões que adiciona uma camada Bi-LSTM sobre a base do modelo BERT;
- [41] BERT4Loc: É um método de recomendação de Pontos de Interesse (POI - locais físicos) que utiliza o modelo BERT exclusivamente para o processamento de texto;
- [42] HybridBERT4Rec: Trata-se de um sistema de recomendação híbrido que se baseia no BERT para combinar métodos tradicionais, como a filtragem colaborativa e a filtragem baseada em conteúdo;

Resultados - Comparação com a literatura

- [43] Spiking Neural Self-attention: É um método voltado para a recomendação baseada em sequências de longo e curto prazo, focando no comportamento histórico do usuário;
- [44] Multimodal Tourism Recommendation: Um método focado em turismo que também utiliza uma arquitetura de "duas torres", mas seu diferencial é combinar características de imagens com características de texto.

Resultados - Comparação com a literatura

- Ao ser comparado com projetos recentes da literatura, o BLDRM-SFE mantém pontuações superiores na maioria das métricas de ranqueamento (NDCG) e precisão (MRR);
- Ao avaliar a mesma base de dados (Yelp), o modelo proposto supera os métodos recentes em NDCG@10 e só é superado em um HR@10.

Pontos fortes

- Consegue fundir dados não estruturados com dados estruturados de maneira harmônica;
- O uso da estrutura de "duas torres" processa usuários e itens de forma paralela e independente;
- Captura da dinâmica temporal por meio do LSTM.

Limitações e Melhorias

- A combinação de modelos profundos torna o processo pesado e exige muito recurso;
  - Os autores citam a limitação, porém não demonstram o tempo de execução de nenhuma etapa, o que dificulta futuras comparações.
- O modelo utiliza o ID dos itens como atributos numéricos juntamente com a descrição, outros atributos como popularidade e categoria poderiam ser adicionados para aumentar a qualidade da representação dos itens.

Conclusão - Síntese

- O modelo BLDRM-SFE provou que a união da análise de textos (BERT) com o comportamento histórico (LSTM) gera predições superiores;
- O método oferece uma solução robusta para recomendação, apesar da complexidade do modelo;
- Hipóteses confirmadas:
  - A integração eficaz de múltiplas fontes de informação melhora o desempenho do sistema na captura dos interesses do usuário;
  - A análise profunda de sentimentos (user review) permite explorar as tendências emocionais dos usuários com maior precisão.

Perguntas?

Links de referência

- GitHub: https://github.com/TiagoMPereira/TP558;
- Quiz: TP558 - Ciclo4 - Tiago - Two Tower Network – Preencher o formulário

Referências

- 40. Azizi, A.; Momtazi, S. SNRBERT: Session-based news recommender using BERT. User Model-User-Adapt. Interact 2024, 34, 1071–1085.
- 41. Bashir, S.R.; Raza, S.; Misic, V.B. BERT4Loc: BERT for Location—POI recommender system. Future Internet 2023, 15, 213.
- 42. Channarong, C.; Paosirikul, C.; Maneeroj, S.; Takasu, A. HybridBERT4Rec: A hybrid (content-based filtering and collaborative f iltering) recommender system based on BERT. IEEE Access 2022, 10, 56193–56206.
- 43. Bai, X.; Huang, Y.; Peng, H.; Yang, Q.; Wang, J.; Liu, Z. Spiking neural self-attention network for sequence recommendation. Appl. Soft Comput. 2025, 169, 112623.
- 44. Cui, Y.; Liang, S.; Zhang, Y.Y. Multimodal representation learning for tourism recommendation with two-tower architecture. PLoS ONE2024, 19, e0299370.

Obrigado!